

UNIVERSIDAD MIGUEL HERNÁNDEZ DE ELCHE
MÁSTER UNIVERSITARIO EN ROBÓTICA



REDES NEURONALES CONVOLUCIONALES PARA EL
ANÁLISIS DE SEÑALES EEG DURANTE LA MARCHA CON
UN EXOESQUELETO

TRABAJO FIN DE MÁSTER

Mayo - 2026

AUTOR: Daniel Rosique Egea

DIRECTOR: Eduardo Iañez Martinez

*“The human brain, sculpted by millions of years of evolution, is the sole architect
of the 'human universe'”*

- MIGUEL NICOLELIS

AGRADECIMIENTOS

Agradezco a ...

Gracias a ...

A ... por ...

RESUMEN

Se utilizarán redes neuronales convolucionales para la detección de patrones cerebrales asociados a la intención de iniciar o detener la marcha en sistemas de asistencia robótica. Este problema resulta clave en el desarrollo de interfaces cerebro-computador aplicadas al control de exoesqueletos, donde la identificación precisa de la intención del usuario es fundamental para garantizar un funcionamiento seguro y eficiente.

El objetivo de este trabajo es analizar el rendimiento de diferentes arquitecturas de redes neuronales convolucionales en la clasificación de señales EEG, así como evaluar distintas estrategias de entrenamiento, incluyendo modelos entrenados con datos del mismo día, enfoques acumulativos y técnicas de fine-tuning. Para ello, se emplean registros de EEG previamente adquiridos, aplicando esquemas de validación cruzada y evaluaciones en entornos pseudo-online que simulan condiciones reales de uso.

Los resultados obtenidos permiten comparar el impacto de la arquitectura, el método de entrenamiento y la variabilidad entre usuarios en el rendimiento del sistema, destacando aquellas configuraciones que maximizan la precisión y reducen los falsos positivos. Asimismo, se identifican diferencias significativas entre los distintos enfoques evaluados, lo que proporciona información relevante para el diseño de sistemas más robustos.

Finalmente, este trabajo sienta las bases para la aplicación de estos modelos en escenarios reales, contribuyendo al desarrollo de sistemas de control más fiables en exoesqueletos y otras tecnologías de asistencia basadas en interfaces cerebro-computador.

ÍNDICE

AGRADECIMIENTOS	III
RESUMEN	V
ÍNDICE DE TABLAS	XI
ÍNDICE DE FIGURAS	XII
ÍNDICE DE CÓDIGOS	XIII
1. Introducción	1
1.1. Motivación	2
1.2. Definición del problema	2
1.3. Objetivos a Conseguir	2
2. Estado del Arte	4
2.1. Conceptos Relevantes del Dominio	4
2.2. Relación con Proyectos Similares	13
2.2.1. Métodos clásicos	13
2.2.2. Deep Learning aplicado a EEG	14
2.2.3. Aplicaciones en exoesqueletos / rehabilitación	14
2.2.4. Limitaciones actuales	14
2.2.5. Tu hueco (esto es clave)	14

3. Material y Métodos	16
3.1. Vision General del Sistema	16
3.2. Materiales	18
3.2.1. Hardware	18
3.2.2. Software	18
3.3. Estructura Dataset	20
3.3.1. Preprocesamiento	22
3.3.2. Preprocesamiento de datos	24
3.4. Modelos utilizados	24
3.4.1. EEGNet	25
3.4.2. DeepConvNet	25
3.4.3. ShallowConvNet	25
3.5. Metodología experimental	25
3.5.1. Variables del estudio	25
3.5.2. Estrategia de entrenamiento	25
3.5.3. Evaluación	26
3.6. Infraestructura Experimental	26
3.6.1. Diseño de experimentos	27
4. Resultados y Discusión	28
4.1. Tarea Estática	28
4.1.1. Comparación de Arquitecturas	28

4.1.2.	Comparación de Método de Entrenamiento	28
4.1.3.	Variabilidad Entre Usuarios	28
4.1.4.	Mejor Configuración	28
4.2.	Tarea Movimiento	28
4.2.1.	Comparación de Arquitecturas	29
4.2.2.	Comparación de Método de Entrenamiento	29
4.2.3.	Variabilidad Entre Usuarios	29
4.2.4.	Mejor Configuración	29
4.3.	Hiperparametros	29
5.	Conclusiones	30
	BIBLIOGRAFÍA	31
	ANEXOS	36
A.	Primer anexo	36
B.	Segundo anexo	37

ÍNDICE DE TABLAS

ÍNDICE DE FIGURAS

2.1. Esquema de las lesiones medulares en función del area de lesión [8] . .	5
2.2. Esquema general de una BCI [azorin Tema32]	13
3.1. Pipeline experimental	17
3.2. Estructura temporal de un trial en términos de ventanas EEG. . . .	21
3.3. Estructura jerárquica de los tensores de entrada y etiquetas utilizados en el modelo.	22

ÍNDICE DE CÓDIGOS

1. Introducción

Según la Organización Mundial de la Salud (OMS), las lesiones medulares afectan a más de 15 millones de personas a nivel mundial. Estas pueden ser ocasionadas tanto por traumatismos como por causas no traumáticas, incluyendo tumores, enfermedades degenerativas y vasculares, infecciones o defectos congénitos. Como consecuencia, producen una pérdida completa o parcial de las funciones sensoriales y/o motoras por debajo del nivel de la lesión, siendo una de las principales causas de discapacidad de larga duración [who·LesionMedula2024].

Las limitaciones en la movilidad derivadas de estas lesiones dificultan la participación plena en la sociedad. En adultos, esto se traduce en tasas de desempleo superiores al 60 %, mientras que en población infantil se observa una menor continuidad en el sistema educativo [who·LesionMedula2024, 1].

La necesidad de abordar los problemas causados por estas lesiones ha impulsado en los últimos años el desarrollo de nuevas terapias y dispositivos de rehabilitación [2].

En este contexto, las Interfaces Cerebro-Computador (BCIs) han emergido como una tecnología prometedora para la asistencia y rehabilitación de pacientes con discapacidad motora, al permitir la comunicación directa entre la actividad cerebral y dispositivos externos. Estas interfaces emplean principalmente señales electroencefalográficas (EEG) para identificar patrones neuronales asociados a la intención de movimiento [3]. Su aplicación en sistemas de asistencia, como exoesqueletos robóticos, abre nuevas posibilidades para mejorar la autonomía y calidad de vida de personas con lesiones medulares.

Sin embargo, la interpretación de las señales EEG presenta importantes desafíos debido a su baja relación señal-ruido y a la elevada variabilidad entre sujetos y sesiones, lo que dificulta el desarrollo de modelos robustos y generalizables [4].

1.1. Motivación

1.2. Definición del problema

Este trabajo aborda la clasificación de señales EEG registradas durante la imaginación activa de tareas de marcha, con el objetivo de detectar patrones cerebrales relacionados con la intención de caminar o detenerse.

El problema se enmarca en el contexto de las BCI orientadas a aplicaciones de rehabilitación, donde resulta fundamental identificar de forma fiable los estados mentales del usuario a partir de señales cerebrales no invasivas.

Para ello, se pretende evaluar la capacidad de diferentes arquitecturas de redes neuronales para extraer características discriminativas a partir de datos EEG pre-procesados, analizando su rendimiento bajo distintos esquemas de entrenamiento y validación.

Además, se estudia la capacidad de generalización de los modelos, evaluando su robustez frente a la variabilidad entre los sujetos y las diferentes sesiones de registro.

1.3. Objetivos a Conseguir

El objetivo principal de este trabajo es evaluar el rendimiento de distintas arquitecturas de redes neuronales en la clasificación de la intención de marcha del usuario a partir de señales EEG.

Para alcanzar este objetivo general, se plantean los siguientes objetivos específicos:

1. Entrenar y evaluar diferentes arquitecturas de redes neuronales
 - EEGNet
 - DeepConvNet
 - ShallowConvNet

2. Evaluar diferentes métodos de entrenamiento
 - Same-day
 - Acumulativo
 - Fine-tuning
 - Same-day + Fine-tuning
3. Analizar variabilidad entre usuarios y su efecto en el rendimiento de los modelos
4. Evaluar el comportamiento de los modelos en diferentes escenarios de validación, incluyendo validación cruzada y entornos pseudo-online.

2. Estado del Arte

La rehabilitación de los pacientes tras una lesión medular es un tema peliagudo, que conlleva un de complicaciones, ya que la rehabilitación de estos pacientes requiere de un gran esfuerzo físico y psicológico. Por estos motivos, en los últimos años, un enfoque que está ganando tracción es el de las interfaces cerebro-computador (BCI), que permiten una rehabilitación asistida más eficiente y con una menor carga al paciente y al profesional [XXX].

Este capítulo trata de introducir los fundamentos que sustentan este trabajo, al igual que se ahonda en el estado actual de las técnicas de Interfaz Cerebro-Computador (BCI) y Electroencephalography (EEG) y sus aplicaciones, para de esta manera poder entender el problema que se pretende resolver y la solución que se pretende dar.

2.1. Conceptos Relevantes del Dominio

Aquí debería poner algooooooooooooooooooooooooooooooooooooo Nose el qué

Lesiones y patologías del sistema nervioso central

El sistema nervioso central (CNS), encargado de la planificación, iniciación y modulación del movimiento, comprende estructuras como la corteza cerebral, el tronco encefálico, el cerebelo y la médula espinal. A través de estas estructuras, el CNS procesa la información sensorial y genera impulsos nerviosos que son transmitidos a los músculos para producir movimiento [5].

Las lesiones o patologías que afectan al CNS pueden dañar tanto las neuronas como las vías de comunicación entre ellas, alterando la transmisión de señales motoras y sensitivas. Como consecuencia, pueden aparecer deficiencias motoras, pérdida de sensibilidad, alteraciones del equilibrio o dificultades en la coordinación del movimiento [5].

Entre las lesiones más relevantes se encuentran las lesiones medulares (SCI), producidas por causas traumáticas o no traumáticas que dañan parcial o totalmente la médula espinal. Este daño interrumpe la transmisión de señales nerviosas entre el cerebro y las regiones corporales situadas por debajo de la lesión. Los síntomas dependen tanto de la localización como de la gravedad del daño. Las lesiones cervicales pueden provocar tetraplejía, mientras que lesiones en regiones más bajas suelen derivar en paraplejía [6, 7].

En la figura 2.1 se puede ver un esquema de las lesiones medulares en función del area de lesión.


		Nivel de la lesión	Efecto*
C T L S		C E R V I C A L	
		Entre C2 y C5	Parálisis de algunos o todos los músculos utilizados para respirar y todos los músculos de brazos y piernas. En general mortal, a menos que se use un ventilador.
		Entre C5 y C6	Parálisis de las piernas, tronco, mano y muñeca. Debilidad de los músculos que mueven el hombro y el codo.
		Entre C6 y C7	Parálisis de las piernas, el tronco y parte de las muñecas y manos. Movimiento normal de hombros y codos.
		Entre C7 y C8	Parálisis de las piernas, el tronco y las manos.
		T O R Á C I C A	
		C8 a T1	Parálisis de piernas y tronco. Debilidad de los músculos que mueven dedos y manos. Síndrome de Horner (con párpado caído, pupila constreñida y sudoración reducida en un lado de la cara). Posiblemente movimiento normal de hombros y codos.
		T2 a T4	Parálisis de piernas y tronco. Pérdida de la sensibilidad debajo de los pezones. Movimiento normal de hombros y codos.
		T5 a T8	Parálisis de las piernas y la parte inferior del tronco. Pérdida de la sensibilidad debajo de la caja torácica.
		T9 a T11	Parálisis de las piernas. Pérdida de la sensibilidad debajo del ombligo.
		T11 a L1	Parálisis y pérdida de sensibilidad en caderas y piernas.
		L U M B A R	
		L2 a S2	Diversos patrones de debilidad y entumecimiento, según el nivel concreto de la lesión.
		S A C R O	
		S3 a S5	Entumecimiento en el perineo.
			*Las lesiones graves pueden causar la pérdida del control de la vejiga y el intestino en cualquier nivel de la médula espinal.

Figura 2.1: Esquema de las lesiones medulares en función del area de lesión [8]

Otra de las principales patologías del CNS son los accidentes cerebrovasculares o ictus. Estos pueden clasificarse en hemorrágicos, cuando se produce la rotura de un vaso sanguíneo cerebral, o isquémicos, cuando una obstrucción reduce o bloquea el flujo sanguíneo. En ambos casos se produce daño neuronal debido a la falta de oxígeno y nutrientes en el tejido cerebral afectado [9]. Los ictus representan una de las principales causas de discapacidad motora adquirida y mortalidad a nivel mundial [5, 9, 10].

A pesar de la gravedad de estas lesiones, existe un potencial de rehabilitación en la neuroplasticidad. La neuroplasticidad es la capacidad del CNS para modificar su estructura y funcionamiento, así como crear nuevas conexiones neuronales en respuesta a estímulos externos o internos [5, 11]. La rehabilitación neurológica busca potenciar esta reorganización funcional de las áreas cerebrales no afectadas [12], creando nuevas conexiones mediante la repetición de tareas.

La rehabilitación constituye un proceso complejo que requiere un enfoque multidisciplinar y tratamientos personalizados. Aunque parte de la recuperación motora suele producirse durante los primeros meses tras la lesión, muchos pacientes continúan presentando secuelas permanentes en fases crónicas [10]. En estos casos, las tecnologías de asistencia, incluyendo los sistemas basados en interfaces cerebro-computadora (BCI), representan una herramienta prometedora para mejorar la autonomía y la interacción con el entorno.

Las limitaciones motoras reducen la calidad de vida de los afectados: Debilidad muscular – Pérdida de la amplitud de movimiento – Deterioro en la generación de fuerzas – Deficiencias en el control motor – Trastornos psicológicos – Limitación de la capacidad para la vida independiente y la autosuficiencia económica de las personas afectadas – Problemas de accesibilidad pública – Complejidad para acceder a la información

El interés por resolver y reducir las limitaciones causadas por problemas motores han incrementado • El objetivo de las tecnologías de asistencia o rehabilitación es: – Neurorehabilitar las capacidades motoras de un paciente con limitaciones de movimiento (rehabilitación) – Reemplazar el movimiento natural mediante acciones

de control sobre un dispositivo externo (asistencia)

- Interfaces Hombre-Máquina interfaces cerebrales (BCI) interfaces oculares (EOG)
- Interfaces que permitan, a partir del movimiento de sus ojos o de los pensamientos o intenciones de la persona – Generar comandos de control

rehabilitación

TEMA 3 robótica médica

Activar la plasticidad para recuperar la movilidad de los pacientes con lesiones motoras.

Activity--Induced Neuroplasticity

- Neuroplasticity and learning can be driven by several key factors taken from motor learning theory Intensity • Repetitions • Duration • Distribution /Frequency • Effort • Difficulty

therapy needs to be intensive, active and challenging for optimal recovery to take place

- Repetitions – More repetitions lead to improved outcomes. A minimal amount of repetitions might be required for recovery to take place – How much is enough? –¿hay un limite en el cual el aumento deja de ser significativo. De hacer 2 horas a 8 no es gran diferencia, pero entre 30 minutos y 1h si que es grande.

- Duration – In general, more therapy hours results in better outcomes. Due to cost and limited manpower current therapies provide only low therapy times. • Distribution and Frequency – There is weak evidence that distributed practice might be better for a safe and effective therapy than massed practice (no rest) -¿tiene que ser constante, no haber demasiada separación entre las sesiones.

Effort – Patients should participate as actively as possible and be cognitively challenged without being overwhelmed. • Difficulty – Training should be adjusted for each patient for an optimal challenge. The optimal learning difficulty is not identical

with the difficulty under which performance is greates

Psychological Factors • Motivation Manner • Task segmentation • Specificity / Functionality • Variability • Initiation • Shaping Information • Instructions • Feedback

Tecnologías de rehabilitación:

• BCI • Exoesqueletos • Interfaces cerebro-máquina ventajas...

las tecnologías de rehabilitación tienen un potencial enorme y ya están empezando a intentar desplegarse en hospitales, hace 10 años a lo mejor estábamos en laboratorios pero ya encontramos por ahí en clínicas que ya lo están tomando como un juguete más de la clínica. Retomando los aspectos anteriores que hemos visto, vamos a decir un robot, un robot es capaz de hacer un mayor número de repeticiones porque estás solo con él, te lo puedes llevar a casa como dijimos. pues además de repeticiones, puedes incrementar el tiempo de la terapia porque, bueno, tú si te lo puedes llevar a casa, pues a lo mejor en lugar de hacer una hora solo por las mañanas cuando te llaman el hospital, pues puedes seguir haciendo ejercicio por la tarde, ¿no? Puedes incrementar el esfuerzo porque podemos simular resistencias, simular como cosas físicas para que la interacción con el paciente, pues, le requiera un esfuerzo, ¿no? Como levantar pesas o al revés, o podemos ajustar para apoyarles y asistirles, ¿no? Que el robot tenga cierta inteligencia y se adapte a las necesidades de la persona, incrementa la motivación del paciente por medio de videojuegos, de interfaces que son atractivas, proporciona información, pues, ya no solo desde el terapeuta, sino que en el mismo interfaz, pues, te puede dar instrucciones, te puede ayudar y podemos dar, pues, instrucciones sonoras, auditivas y demás, y visuales para que se entiendan mucho más las instrucciones del terapeuta y luego, pues, como cualquier software, pues, permite planificar una terapia ABCD, pues, a la perfección. O sea que puede venir el profesional, decir, pues mira, te planifico una terapia de una hora con x de dispositivos y tú como gimnasio vas pasando de uno a otro y lo vas haciendo. Como os decía, pues nada, esto ya en 2010,

problemas....

Exoesqueletos

es un dispositivo robótico que se alinea con las articulaciones de, en este caso, del brazo, lo que estamos viendo en el vídeo, y que lo que hacen es que asisten de forma completa al brazo. Es decir, es una estructura rígida donde yo puedo controlar cada uno de tus articulaciones. Yo diseño exactamente para que las actuaciones estén orientadas y alineadas con los ejes de rotación del brazo y puedo moverte X grados de codo, X grados de hombro y lo mismo con la pierna. interesante puedo monitorizar el movimiento de cada una de esas articulaciones, tengo un control muy fino de lo que es el miembro que estoy utilizando, el miembro superior o inferior

no es que este no es que el objetivo sea llegar a sistemas no actuados sino que lo que buscamos es que la actuación sea más inteligente es decir que se adapte verdaderamente a tus necesidades un terapeuta no te coge el brazo y te mueve para que llegues te intenta hacer que lo hagas tú y si ve que no puedes te ayuda pues buscamos intentar replicar esa cooperación y eso es lo que es como más la parte de lo que estamos trabajando ahora ahora que hay una computación mucho mayor y que hay como estrategias mucho más avanzadas no se ha logrado todavía pero se está haciendo avances en intentar llevar a controles o dispositivos que sean más inteligentes específicamente por medio de...

Electroencefalografía (EEG)

La electroencefalografía (EEG) consiste en la captación de la actividad eléctrica cerebral generada por la comunicación entre neuronas. Estas señales se registran mediante electrodos no invasivos colocados sobre el cuero cabelludo y son posteriormente amplificadas y representadas en función del tiempo [13, 14].

Dentro de estas señales se encuentran respuestas neuronales asociadas a distintos tipos de eventos (sensoriales, cognitivos y motores) conocidas como potenciales relacionados con eventos (ERP), así como aquellas asociadas a la imaginación motora (MI) [13, 15].

Estas respuestas se denominan potenciales debido a que reflejan variaciones en los potenciales eléctricos registrados. Entre los relacionados con la imaginación moto-

ra destacan los potenciales corticales relacionados con el movimiento (MRCP), los cuales permiten detectar la intención de movimiento antes de que este ocurra [16].

Es común realizar una separación de estas señales en función de su frecuencia, ya que se ha demostrado que distintas bandas de frecuencia se corresponden con estados mentales concretos [14, 17].

- **Delta** (<4 Hz): Ubicadas en la región frontal en adultos y posterior en los niños. Se asocian principalmente al sueño, siendo también frecuentes en niños y en tareas de atención sostenida.
- **Theta** (4–7 Hz): Predominan en las regiones parietal y temporal en niños. En adultos, aparecen durante algunas fases del sueño o en estados de estrés
- **Alpha** (8–13 Hz): Se localizan en la región occipital. Se asocian a estados de relajación con los ojos cerrados, disminuyendo durante la concentración y el sueño.
- **Beta** (13–30 Hz): Son detectadas en los lóbulos frontal y parietal y presentan una distribución relativamente simétrica. Aparecen en tareas de calma activa con los ojos abiertos. Pero también pueden aparecer durante actividad mental intensa o situaciones de estrés.
- **Gamma** (>30 Hz): Se han relacionado con actividad en la región somatosensorial durante tareas de procesamiento multisensorial y en procesos cognitivos complejos, como la memoria.
- **Mu** (8–12 Hz): Se localizan en el córtex sensoriomotor y se asocian a la actividad de este sistema en reposo.

El análisis de señales EEG es una herramienta muy potente que permite revelar información sobre la actividad cerebral de un individuo, teniendo muchas aplicaciones en neurociencia y en BCI [18].

Entre las principales ventajas del uso de EEG se encuentran [13, 14, 19]:

- **Alta resolución temporal:** Permite registrar cambios en la actividad cerebral en el rango de milisegundos.

Medición directa de actividad eléctrica: A diferencia de otras técnicas que estiman la actividad cerebral de forma indirecta mediante cambios en los niveles de oxígeno en sangre, las señales EEG registran directamente la actividad eléctrica generada por poblaciones neuronales.

- **Carácter no invasivo:** La señal puede registrarse mediante electrodos colocados sobre el cuero cabelludo, sin necesidad de procedimientos quirúrgicos. Esto reduce el riesgo de sufrir complicaciones durante la captura de la señal y las molestias a los pacientes.
- **Bajo coste relativo:** En comparación con otras técnicas de neuroimagen, como la resonancia magnética funcional, los sistemas EEG suelen ser más accesibles y fáciles de utilizar.

Algunas de las desventajas que convierten a estas señales en difíciles de analizar son las siguientes [13, 20, 21]:

- **Baja resolución espacial:** Las señales EEG no permiten localizar con precisión la fuente de actividad cerebral, ya que representan una media de múltiples fuentes de actividad neuronales.
- **Variabilidad inter-sujeto e intra-sujeto:** Existe una gran variabilidad en las señales EEG entre diferentes individuos, lo que dificulta la observación de patrones en ellas. A su vez, las propiedades estadísticas de las señales pueden variar a lo largo del tiempo, incluso para un mismo sujeto y tarea.
- **Ruido:** Las señales EEG son altamente susceptibles a artefactos, como el movimiento, la actividad muscular (EMG) o interferencias externas. Además, la amplitud de las señales EEG es muy baja en comparación con el ruido presente, lo que exige un preprocesado avanzado para eliminar el ruido y mejorar la calidad de las señales.

Estas limitaciones justifican el uso de técnicas avanzadas de procesamiento y aprendizaje automático. En los últimos años el uso de modelos de aprendizaje profundo (deep learning) ha supuesto un avance significativo, facilitando el desarrollo de aplicaciones más prácticas y reduciendo la dependencia de procesamiento manual por parte de expertos [18].

Potenciales relacionados a eventos (ERP)

Intención de movimiento (MI)

Interfaz Cerebro-Computador (BCI)

Una interfaz cerebro-máquina es un sistema que procesa señales cerebrales y las traduce en comandos que pueden ser utilizados por un sistema externo o interno de control sin realizar ningún movimiento muscular [22]. El término BCI se utiliza para referirse a un amplio conjunto de tecnologías que permiten la comunicación directa entre el cerebro y un dispositivo externo.

Las interfaces cerebro-computador (BCI) permiten la comunicación directa entre el cerebro y un dispositivo externo, sin necesidad de vías motoras convencionales...

Como tecnología asistiva Cuando el daño motor de un individuo ya es crónico, estas interfaces se pueden utilizar como herramienta de comunicación, para controlar miembros artificiales (sustitución motora) o incluso para el ocio

Sustitución motora

- El concepto de movilidad asistiva se puede encuadrar dentro de la sustitución motora
- Un ejemplo es el uso de sillas de ruedas controladas por BCI
- La silla de ruedas, es considerada, por muchos usuarios como parte de su propio cuerpo (embodiment) y funciona de forma equivalente a una prótesis




Figura 2.2: Esquema general de una BCI [azorin'Tema32]

Aquí puedes conectar con tu caso (exoesqueleto)

Deep Learning en EEG

2.2. Relación con Proyectos Similares

Estructura muy clara:

2.2.1. Métodos clásicos

- LDA, SVM
- Features manuales
- Limitaciones

2.2.2. Deep Learning aplicado a EEG

CNNs (EEGNet, DeepConvNet...)

Qué han conseguido

Problemas abiertos:

generalización

dependencia del usuario

2.2.3. Aplicaciones en exoesqueletos / rehabilitación

Uso de BCI para control

Problema clave:

detección fiable de intención

2.2.4. Limitaciones actuales

Aquí es donde te preparas el terreno:

variabilidad entre sujetos

necesidad de recalibración

falsos positivos peligrosos

falta de evaluación en escenarios realistas

2.2.5. Tu hueco (esto es clave)

Termina con algo así:

“En este contexto, este trabajo se centra en...”

Aquí conectas directamente con tu TFM:

comparación de métodos de entrenamiento

evaluación pseudo-online

análisis sistemático

3. Material y Métodos

3.1. Vision General del Sistema

Se ha definido un pipeline de ejecución que permite realizar múltiples experimentos de forma iterativa y automatizada. Este pipeline está compuesto por distintos módulos encargados de gestionar el preprocesamiento de los datos, la configuración de los modelos, el entrenamiento y la evaluación de los mismos.

Con el objetivo de facilitar la reproducibilidad y la exploración sistemática de parámetros, el código se ha estructurado como un microframework que permite modificar de forma sencilla las variables de estudio, así como controlar la ejecución de los experimentos. Este enfoque ha resultado especialmente útil dado el elevado número de ejecuciones.

Para organizar la ejecución, se ha definido una estructura jerárquica en tres niveles:

- **Experimento:** nivel superior que agrupa el conjunto completo de configuraciones evaluadas. Un experimento consiste en la ejecución sistemática de múltiples combinaciones de parámetros.
- **Iteración:** cada una de las ejecuciones individuales del pipeline dentro de un experimento, asociada a una combinación específica de parámetros (arquitectura, método de entrenamiento y tipo de tarea).
- **Entrenamiento:** nivel más bajo de la jerarquía, correspondiente al entrenamiento y evaluación de un modelo para un usuario y sesión concretos dentro de una iteración.

De este modo, cada experimento está compuesto por múltiples iteraciones, y cada iteración incluye varios entrenamientos, uno por cada usuario y sesión del dataset. Los experimentos se definen mediante la combinación de distintos parámetros, entre los que destacan el tipo de tarea, la arquitectura del modelo y el método de entrenamiento. Para cada combinación se ejecuta una iteración independiente

En cada iteración, el sistema inicializa los parámetros de entrenamiento y carga el conjunto de datos correspondiente al tipo de tarea. A continuación, se ejecuta el método de entrenamiento seleccionado, en el que se itera sobre los distintos usuarios y sesiones disponibles en el dataset. Para cada caso, se inicializa el modelo, se realiza el entrenamiento y se evalúa su rendimiento.

Finalmente, los resultados obtenidos, junto con los parámetros utilizados, se almacenan de forma estructurada, permitiendo su posterior análisis.

Este proceso permite realizar un estudio posterior de los resultados obtenidos por cada combinación de parámetros definida.

La Figura 3.1 resume la organización jerárquica del pipeline experimental.




Figura 3.1: Pipeline experimental

3.2. Materiales

3.2.1. Hardware

Para ejecutar los distintos entrenamientos se ha utilizado un ordenador con las siguientes características:

- **CPU:** Intel Core i9-14900HX
- **RAM:** 31 GiB
- **GPU:** NVIDIA GeForce RTX 4060
- **GPU RAM:** 8 GiB

Estas características han resultado suficientes para completar los experimentos planteados sin limitaciones críticas. El tiempo medio de entrenamiento por iteración ha sido aproximadamente 40 minutos, dependiendo de la configuración del modelo y de los parámetros de entrenamiento.

El tiempo total de cómputo se estima mediante:

$$\text{Tiempo total (h)} = \frac{N_{\text{iteraciones}} \times t_{\text{iteración}}}{60}$$

Donde $N_{\text{iteraciones}} = 1917$ y $t_{\text{iteración}} = 40\text{minutos}$, resultando en un tiempo total aproximado de 766.8 horas ($\approx 31\text{días}$).

El uso de hardware con mayores prestaciones permitiría reducir significativamente el tiempo total de entrenamiento y facilitar la realización de un mayor número de experimentos.

3.2.2. Software

Para el desarrollo del proyecto se ha utilizado una infraestructura basada en herramientas ampliamente empleadas en el ámbito del aprendizaje automático y la

ingeniería de software.

Como lenguaje de programación principal se ha utilizado Python¹, debido a su amplio ecosistema de librerías científicas y de aprendizaje automático, así como su facilidad de integración con frameworks de alto nivel.

Para la construcción y entrenamiento de los modelos se han utilizado TensorFlow² y Keras³, frameworks de aprendizaje profundo que permiten definir, entrenar y evaluar redes neuronales de forma eficiente. Keras se ha empleado como interfaz de alto nivel sobre TensorFlow, facilitando la experimentación rápida con distintas arquitecturas.

Durante las etapas iniciales del proyecto se empleó Jupyter Notebook⁴ para la realización de pruebas exploratorias y la visualización preliminar de resultados. Sin embargo, su uso fue descartado en fases posteriores debido a la dificultad para mantener una estructura de código modular y escalable en experimentos de mayor complejidad.

Posteriormente, se adoptó Visual Studio Code⁵ como entorno de desarrollo principal, debido a su capacidad para gestionar múltiples tipos de archivos y su integración con herramientas de desarrollo. Se utilizaron extensiones específicas para Python, Jupyter y GitHub, permitiendo un flujo de trabajo unificado.

Como sistema de control de versiones se ha utilizado GitHub⁶, que facilita la gestión del código, el seguimiento de cambios y la colaboración con el tutor del proyecto. Además, permite la sincronización del repositorio entre distintos dispositivos de forma eficiente.

Para la visualización de resultados se ha utilizado Vega-Altair⁷, una librería de visualización estadística declarativa enfocada en la simplicidad, eficiencia y legibilidad. A diferencia de enfoques imperativos como Matplotlib, Altair permite definir visualizaciones de forma estructurada y reproducible, enfocándose en lo que se quiere

¹<https://www.python.org/>

²<https://www.tensorflow.org/>

³<https://keras.io/>

⁴<https://jupyter.org/>

⁵<https://code.visualstudio.com/>

⁶<https://github.com/>

⁷<https://altair-viz.github.io/>

observar en lugar de en los detalles de la implementación. Esto conduce a un código más limpio y legible[23]

Como gestor de base de datos se ha utilizado DuckDB⁸, un sistema de bases de datos analítico embebido que permite realizar consultas SQL de forma eficiente directamente sobre archivos locales. Su integración con Python y su alto rendimiento lo hacen especialmente adecuado para el procesamiento de grandes volúmenes de resultados experimentales[24].

Todas estas herramientas han sido integradas en un flujo de trabajo unificado orientado a la ejecución reproducible de experimentos.

3.3. Estructura Dataset

El dataset incluye registros de 5 sujetos, adquiridos a lo largo de 5 días diferentes (de lunes a viernes). Para cada día, se realizaron 11 ensayos (*trials*), y cada ensayo se segmentó en 56 ventanas temporales, lo que da lugar a un total de:

$$5 \times 5 \times 11 \times 56 = 15400 \text{ ventanas}$$

Cada *trial* corresponde a una secuencia estructurada de tareas mentales, compuesta por:

- 14 ventanas de relajación inicial,
- 28 ventanas de imaginación motora de la marcha,
- 14 ventanas finales de relajación.

Un esquema de esta segmentación temporal se muestra en la Figura 3.2.

⁸<https://duckdb.org/>

Relajación	Imaginación motora	Relajación
Ventanas 1–14	Ventanas 15–42	Ventanas 43–56
14 ventanas	28 ventanas	14 ventanas

Figura 3.2: Estructura temporal de un trial en términos de ventanas EEG.

El usuario alterna entre las dos tareas (static, y motion) durante los ensayos para que no sea tan repetitivo.

Cada instancia del dataset corresponde a una ventana de 400 muestras de señal EEG. Dado que la frecuencia de muestreo es de 200 Hz, cada ventana representa 2 s de señal. Las ventanas se organizan secuencialmente dentro de cada trial con un desplazamiento temporal de 0.5 s entre ventanas consecutivas.

Antes de cada tarea mental se le da una instrucción al usuario, esta instrucción puede alterar el clasificador, ya que no corresponde con ninguna tarea mental definida, por lo que se eliminan durante el preprocesamiento.

Adicionalmente, antes de cada ensayo se incluía un periodo inicial de duración aleatoria en el que el sujeto realizaba una tarea mental distinta. El objetivo de este periodo es el de reducir artefactos y ruido en la señal (convergencia de filtros). Este segmento fue eliminado durante el procesamiento previo del dataset.

Cada ventana de datos EEG está formada por 27 canales y 400 muestras por canal. Los 27 canales corresponden a los electrodos seleccionados para la adquisición de la señal. Por tanto, cada instancia del dataset puede interpretarse como una matriz de tamaño 27×400 , donde cada fila representa la evolución temporal de un canal EEG durante la ventana analizada.

Los 27 canales EEG utilizados fueron: F3, FZ, FC1, FCZ, C1, CZ, CP1, CPZ, FC5, FC3, C5, C3, CP5, CP3, P3, PZ, F4, FC2, FC4, FC6, C2, C4, CP2, CP4, C6, CP6 y P4. Estos electrodos se colocaron siguiendo el sistema internacional 10-10.

Los datos y las etiquetas están alineados a nivel de ventana, utilizando un fichero auxiliar que permite asociar cada segmento de señal con su correspondiente etiqueta.

3.3.1. Preprocesamiento

A partir de los datos disponibles, se ha realizado una reorganización estructural de los mismos con el objetivo de facilitar su uso en los modelos propuestos. En concreto, los datos se han reestructurado en tensores de seis dimensiones:

Input tensor shape: (5, 5, 11, 56, 27, 400)						
Dim.	1	2	3	4	5	6
Name	Users	Days	Trials	Windows	Channels	Samples
Size	5	5	11	56	27	400

Labels tensor shape: (5, 5, 11, 56, 1)					
Dim.	1	2	3	4	5
Name	Users	Days	Trials	Windows	Label
Size	5	5	11	56	1

Figura 3.3: Estructura jerárquica de los tensores de entrada y etiquetas utilizados en el modelo.

Esta reorganización permite explotar explícitamente la estructura jerárquica del dataset durante el entrenamiento y la evaluación de los modelos.

En cuanto a la partición de los datos, se ha realizado una división entrenamiento-test con una proporción del 70 % y 30 %, respectivamente. Esta separación se ha llevado a cabo a nivel de *trial*, manteniendo la coherencia temporal de las ventanas.

La selección de los datos de test no se ha realizado de forma aleatoria, sino utilizando los últimos *trials* de cada sujeto y día. Esta decisión se basa en la hipótesis de que los sujetos presentan una mejora progresiva en el control de la imaginación motora a lo largo de la sesión, lo que permite evaluar el modelo en condiciones más estables.

Finalmente, no se han aplicado técnicas adicionales de preprocesamiento o filtrado sobre las señales EEG más allá de la estructuración descrita.

■ adsad

¿Qué preprocesado EEG se aplicó?

filtrado (bandpass?) eliminación de artefactos (ICA?) normalización?

El dataset utilizado se compone por dos ficheros de labels y dos de datos de entrenamiento. Los labels contienen la intención de movimiento de cada canal de EEG, mientras que los datos contienen las lecturas de cada canal de EEG.

Estos ficheros están separados por la tarea a analizar, de esta forma tenemos los cuatro ficheros:

	Labels	Training
Static	labels_static_data.mat	training_static_data.mat
Motion	labels_motion_data.mat	training_motion_data.mat

- labels_static_data.mat
- training_static_data.mat
- labels_motion_data.mat
- training_motion_data.mat

Los ficheros contienen la siguiente estructura de datos: Los labels tienen la forma (15400, 1), mientras que los datos tienen la forma (15400, 27, 400). Los ficheros de labels contienen una matriz con el numero de ventanas y una columna con la intención de movimiento Los ficheros de training contienen una matriz de tamaño $N \times C \times S$, donde N es el número de ventanas, C es el número de canales y S es el número de muestras. En el caso de este experimento $N = 15400$ $C = 27$ y $S = 400$. Las muestras son obtenidas durante 2 segundos a 200hz

The 27 channels selected for acquisition were: F3, FZ, FC1, FCZ, C1, CZ, CP1, CPZ, FC5, FC3, C5, C3, CP5, CP3, P3, PZ, F4, FC2, FC4, FC6, C2, C4, CP2, CP4, C6, CP6, P4. They were placed following the 10-10 international system. Four electrodes were located next to the eyes to record electrooculography (EOG) and ground and reference electrodes were located on the right and left ear lobes, respectively. Each channel signal was amplified with BrainVision BrainAmp amplifier.

Se tienen los datos de 5 usuarios, con 5 días cada uno, 11 trials por día, cada día, 56 ventanas por trial. Por lo tanto, se tienen $5 \times 5 \times 11 \times 56 = 15400$ ventanas.

Cada trial corresponde a una secuencia de dos tareas mentales, relajación e imaginación de la marcha, que se repite en intervalos de 14 ventanas temporales ($0.5s \times \text{ventana} = 0.7s$) de relajación, 28 de imaginación de la marcha ($0.5s \times \text{ventana} = 1.4s$) y finalmente otras 14 de relajación. Se cuenta con un periodo inicial de duración aleatoria en la cual se le pedía al sujeto realizar una tarea mental compleja, diferente a la imaginación motora. Este periodo se utiliza para eliminar ruidos en la señal EEG y se ha eliminado del dataset final.

Un esquema de las ventanas se puede ver en la figura ??.

3.3.2. Preprocesamiento de datos

Los datos han sido procesados previamente en otro estudio.

La separación entre los datos de entrenamiento y testeo se ha hecho en un 70 % de entrenamiento y 30 % de testeo y se aplica al nivel de trial. Esta separación se ha hecho para cada entrenamiento del modelo y se toma en cuenta el usuario y día de cada uno. No se ha hecho de manera aleatoria, sino que se han utilizado para testeo empezando por el final de la lista de trials.

La razón de esta decisión es que en los primeros trials el sujeto suele presentar un menor control sobre su imaginación motora.

Más allá de estos preprocesamientos, no se ha hecho nada más

3.4. Modelos utilizados

Aquí metes:

3.4.1. EEGNet

3.4.2. DeepConvNet

3.4.3. ShallowConvNet

(si lo usas)

3.5. Metodología experimental

Aquí es donde entra todo tu proyecto de verdad.

3.5.1. Variables del estudio

Muy importante estructurarlo así:

Arquitectura del modelo

Método de entrenamiento:

same-day

acumulativo

fine-tuning

Tarea:

static / motion

Usuario

3.5.2. Estrategia de entrenamiento

epochs

batch size

callbacks:

early stopping

reduce LR

función de pérdida

métrica (accuracy)

No te lées demasiado, pero deja claro cómo entrenas

3.5.3. Evaluación

MUY importante:

validación cruzada

pseudo-online

explica qué significa pseudo-online (aunque sea breve)

3.6. Infraestructura Experimental

Aquí metes tu microframework (esto es TU aporte técnico fuerte)

sistema para ejecutar múltiples experimentos gestión de parámetros almacenamiento de resultados (DuckDB) automatización

Esto es diferencial → véndelo bien

Se ha programado un microframework para el desarrollo de experimentos de Machine Learning.

Como se ha comentado en el apartado ??, se ha realizado la comparación de tres modelos de redes neuronales convolucionales para la clasificación de la intención de

caminar o detenerse con un exoesqueleto. Se ha utilizado un dataset de EEG con 27 canales, obtenido de una muestra de un estudio previo XXXXXX. Los parametros a comparar son la arquitectura de la red, el metodo de entrenamiento, la tarea a predecir y la variabilidad entre usuarios.

Al necesitarse de cientos de ejecuciones para obtener todos los datos necesarios, durante las etapas iniciales se tomó la decisión de enfocar el proyecto de manera horizontal, preparando una base de ejecución sobre la cual modificar facilmente todo lo necesario para cada ejecución y permitiendo ejecutar multiples experimentos de manera secuencial.

(((((Aquí no sé si ir diicendo TOOOOODO lo que he ido poniendo en el código. Puedo ir siguiendo el timeline de Github y hacer un resumen de los commits))))))

3.6.1. Diseño de experimentos

Aquí explicas cómo organizaste TODO

combinaciones de parámetros n^o de ejecuciones cómo comparas resultados

Esto conecta directamente con Results luego

4. Resultados y Discusión

se describirían y analizarían los resultados obtenidos siguiendo la metodología propuesta.

4.1. Tarea Estática

4.1.1. Comparación de Arquitecturas

Me da igual todo, solo me centro en los modelos. hago avg y std con los metodos y los usuarios

4.1.2. Comparación de Método de Entrenamiento

Me da igual todo, solo me centro en los metodos. hago avg y std con los modelos y los usuarios

4.1.3. Variabilidad Entre Usuarios

Me da igual todo, solo me centro en los usuarios. hago avg y std con los metodos y los modelos

4.1.4. Mejor Configuración

De aquí sacaría algo rollo: La mejor combinación en cuanto a usuario+metodo+modelo
–ej (gráfica solamente de usuario1+entrenamientoA+eegnet)

4.2. Tarea Movimiento

mismo esquema

4.2.1. Comparación de Arquitecturas

4.2.2. Comparación de Método de Entrenamiento

4.2.3. Variabilidad Entre Usuarios

4.2.4. Mejor Configuración

4.3. Hiperparametros

Analysis EEGNet hyperparameters comparison plots

5. Conclusiones

en funci3n de los resultados obtenidos, se expondr3an las conclusiones de la investigaci3n y se propondr3an trabajos futuros.

BIBLIOGRAFÍA

- [1] S. A. Bravo, J. A. Porras y M. J. Á. Urricelqu. «La exclusión social, una problemática estructural entre las personas con discapacidad». En: *Áreas. Revista Internacional de Ciencias Sociales* 36 (1 de nov. de 2017), págs. 167-181. ISSN: 1989-6190. URL: <https://revistas.um.es/areas/article/view/308211> (visitado 29-04-2026).
- [2] G. Morone y R. S. Calabrò. «Neurorehabilitation Insights in 2024: Where Neuroscience Meets Next-Gen Tech». En: *Brain Sciences* 15.10 (25 de sep. de 2025), pág. 1043. ISSN: 2076-3425. DOI: 10.3390/brainsci15101043. PMID: 41154139. URL: <https://pmc.ncbi.nlm.nih.gov/articles/PMC12562376/> (visitado 04-05-2026).
- [3] M. T. Sadiq, M. Z. Aziz, A. Almogren, A. Yousaf, S. Siuly y A. U. Rehman. «Exploiting Pretrained CNN Models for the Development of an EEG-based Robust BCI Framework». En: *Computers in Biology and Medicine* 143 (1 de abr. de 2022), pág. 105242. ISSN: 0010-4825. DOI: 10.1016/j.combiomed.2022.105242. URL: <https://www.sciencedirect.com/science/article/pii/S0010482522000348> (visitado 27-04-2026).
- [4] S. Yun. «Advances, Challenges, and Prospects of Electroencephalography-Based Biomarkers for Psychiatric Disorders: A Narrative Review». En: *Journal of Yeungnam Medical Science* 41.4 (9 de sep. de 2024), págs. 261-268. ISSN: 2799-8010. DOI: 10.12701/jyms.2024.00668. PMID: 39246060. URL: <https://pmc.ncbi.nlm.nih.gov/articles/PMC11534409/> (visitado 06-05-2026).
- [5] M. C. Emos y S. Agarwal. «Neuroanatomy, Upper Motor Neuron Lesion». En: *StatPearls*. Treasure Island (FL): StatPearls Publishing, 2026. PMID: 30725990. URL: <http://www.ncbi.nlm.nih.gov/books/NBK537305/> (visitado 12-05-2026).

- [6] K. Margetis, J. M. Das y P. D. Emmady. «Spinal Cord Injuries». En: *StatPearls*. Treasure Island (FL): StatPearls Publishing, 2026. PMID: 32809556. URL: <http://www.ncbi.nlm.nih.gov/books/NBK560721/> (visitado 12-05-2026).
- [7] National Institute of Neurological Disorders and Stroke. *Spinal Cord Injury — National Institute of Neurological Disorders and Stroke*. URL: <https://www.ninds.nih.gov/health-information/disorders/spinal-cord-injury> (visitado 12-05-2026).
- [8] I. Corral López, M. Morales Castillo y M. O. González Oria. *Traumatismo medular*. Manuales Clínicos. 2 de nov. de 2023. URL: <https://manualclinico.hospitaluvrocio.es/urgencias-de-traumatologia/patologia-de-cabeza-y-tronco/traumatismo-medular/> (visitado 12-05-2026).
- [9] S. J. Murphy y D. J. Werring. «Stroke: Causes and Clinical Features». En: *Medicine (Abingdon, England : UK Ed.)* 48.9 (sep. de 2020), págs. 561-566. ISSN: 1357-3039. DOI: 10.1016/j.mpmed.2020.06.002. PMID: 32837228. URL: <https://pmc.ncbi.nlm.nih.gov/articles/PMC7409792/> (visitado 12-05-2026).
- [10] Z. Gao, Z. Pang, Y. Chen, G. Lei, S. Zhu, G. Li, Y. Shen y W. Xu. «Restoring After Central Nervous System Injuries: Neural Mechanisms and Translational Applications of Motor Recovery». En: *Neuroscience Bulletin* 38.12 (1 de dic. de 2022), págs. 1569-1587. ISSN: 1995-8218. DOI: 10.1007/s12264-022-00959-x. URL: <https://doi.org/10.1007/s12264-022-00959-x> (visitado 12-05-2026).
- [11] M. Puderbaugh y P. D. Emmady. «Neuroplasticity». En: *StatPearls*. Treasure Island (FL): StatPearls Publishing, 2026. PMID: 32491743. URL: <http://www.ncbi.nlm.nih.gov/books/NBK557811/> (visitado 13-05-2026).

- [12] R. Di Palma, L. Falco, A. Coccia, F. Amitrano, G. Pagano y G. D’Addio. «Frontiers in Neuro-Rehabilitation: Neural Basis of Cognitive Contributions to Movement across Neurological Populations». En: *Frontiers in Neurology* 16 (4 de jul. de 2025). ISSN: 1664-2295. DOI: 10.3389/fneur.2025.1638254. URL: <https://www.frontiersin.org/journals/neurology/articles/10.3389/fneur.2025.1638254/full> (visitado 13-05-2026).

- [13] S. J. Luck. *An Introduction to the Event-Related Potential Technique*. 2.^a ed. Cambridge, MA, USA: MIT Press, 30 de mayo de 2014. 416 págs. ISBN: 978-0-262-52585-5.

- [14] D. L. Sherman y N. V. Thakor. «EEG Signal Processing: Theory and Applications». En: *Neural Engineering*. Ed. por B. He. Cham: Springer International Publishing, 2020, págs. 97-129. ISBN: 978-3-030-43395-6. DOI: 10.1007/978-3-030-43395-6_3. URL: https://doi.org/10.1007/978-3-030-43395-6_3 (visitado 06-05-2026).

- [15] B. Jiang, X. Wang, D. He, S. Cheng, M. Liao, D. Miao, Q. Xia, Y. Zhao y G. Li. «A Comprehensive Review of Deep Learning for Motor Imagery EEG: From Healthy Subjects to Patients». En: *Biomedical Signal Processing and Control* 117 (15 de mayo de 2026), pág. 109680. ISSN: 1746-8094. DOI: 10.1016/j.bspc.2026.109680. URL: <https://www.sciencedirect.com/science/article/pii/S174680942600234X> (visitado 05-05-2026).

- [16] I. K. Niazi, N. Jiang, O. Tiberghien, J. F. Nielsen, K. Dremstrup y D. Farina. «Detection of Movement Intention from Single-Trial Movement-Related Cortical Potentials». En: *Journal of Neural Engineering* 8.6 (oct. de 2011), pág. 066009. ISSN: 1741-2552. DOI: 10.1088/1741-2560/8/6/066009. URL: <https://doi.org/10.1088/1741-2560/8/6/066009> (visitado 05-05-2026).

- [17] M. Roohi-Azizi, L. Azimi, S. Heysieattalab y M. Aamidfar. «Changes of the Brain’s Bioelectrical Activity in Cognition, Consciousness, and Some Men-

- tal Disorders». En: *Medical Journal of the Islamic Republic of Iran* 31 (3 de sep. de 2017), pág. 53. ISSN: 1016-1430. DOI: 10.14196/mjiri.31.53. PMID: 29445682. URL: <https://pmc.ncbi.nlm.nih.gov/articles/PMC5804435/> (visitado 06-05-2026).
- [18] A. Craik, Y. He y J. L. Contreras-Vidal. «Deep Learning for Electroencephalogram (EEG) Classification Tasks: A Review». En: *Journal of Neural Engineering* 16.3 (abr. de 2019), pág. 031001. ISSN: 1741-2552. DOI: 10.1088/1741-2552/ab0ab5. URL: <https://doi.org/10.1088/1741-2552/ab0ab5> (visitado 27-04-2026).
- [19] A. Telpaz, R. Webb y D. Levy. «Using EEG to Predict Consumers' Future Choices». En: *Journal of Marketing Research* (1 de ago. de 2015). DOI: 10.1509/jmr.13.0564.
- [20] L. S. Vidyaratne y K. M. Iftexharuddin. «Real-Time Epileptic Seizure Detection Using EEG». En: *IEEE Transactions on Neural Systems and Rehabilitation Engineering* 25.11 (nov. de 2017), págs. 2146-2156. ISSN: 1558-0210. DOI: 10.1109/TNSRE.2017.2697920. URL: <https://ieeexplore.ieee.org/document/7911296> (visitado 06-05-2026).
- [21] S. Saha y M. Baumert. «Intra- and Inter-subject Variability in EEG-Based Sensorimotor Brain Computer Interface: A Review». En: *Frontiers in Computational Neuroscience* 13 (21 de ene. de 2020), pág. 87. ISSN: 1662-5188. DOI: 10.3389/fncom.2019.00087. PMID: 32038208. URL: <https://pmc.ncbi.nlm.nih.gov/articles/PMC6985367/> (visitado 06-05-2026).
- [22] M. J. Young, D. J. Lin y L. R. Hochberg. «Brain-Computer Interfaces in Neurorecovery and Neurorehabilitation». En: *Seminars in neurology* 41.2 (abr. de 2021), págs. 206-216. ISSN: 0271-8235. DOI: 10.1055/s-0041-1725137. PMID: 33742433. URL: <https://pmc.ncbi.nlm.nih.gov/articles/PMC8768507/> (visitado 10-05-2026).

- [23] *Introduction to Altair in Python*. GeeksforGeeks. 19 de jul. de 2025. URL: <https://www.geeksforgeeks.org/python/introduction-to-altair-in-python/> (visitado 07-04-2026).

- [24] *Why DuckDB*. DuckDB. 2026. URL: https://duckdb.org/why_duckdb.html (visitado 07-04-2026).

ANEXOS

tantos como se considere necesario en funci3n de los aspectos concretos que se quieran especificar.

A. Primer anexo

Contenido del primer anexo (texto, tablas, figuras, c3digos, etc.)

B. Segundo anexo

Contenido del segundo anexo (texto, tablas, figuras, códigos, etc.)

interwordspace: 3.91663pt

interwordstretch: 1.95831pt

emergencystretch: 35.24963pt