

UNIVERSIDAD MIGUEL HERNÁNDEZ DE ELCHE
MÁSTER UNIVERSITARIO EN ROBÓTICA



REDES NEURONALES CONVOLUCIONALES PARA EL
ANÁLISIS DE SEÑALES EEG DURANTE LA MARCHA CON
UN EXOESQUELETO

TRABAJO FIN DE MÁSTER

Mayo - 2026

AUTOR: Daniel Rosique Egea

DIRECTOR: Eduardo Iañez Martinez

*“The human brain, sculpted by millions of years of evolution, is the sole architect
of the 'human universe'”*

- MIGUEL NICOLELIS

AGRADECIMIENTOS

Agradezco a mi tutor del proyecto, Eduardo Iáñez, por su paciencia en el desarrollo de este trabajo y por la ayuda que me ha proporcionado durante todo el proceso. También por permitirme acercarme a la neuro-robótica y al análisis de señales EEG.

Gracias también a mi pareja por apoyarme y motivarme en los momentos en los que me he encontrado perdido en el proyecto.

Gracias a mi familia y a mis compañeros de trabajo por recordarme la importancia de este trabajo y por ayudarme a mantenerme motivado durante el proceso de desarrollo.

Finalmente, gracias a todos los que han estado conmigo durante este año con tantos cambios y dificultades.

RESUMEN

Se utilizarán redes neuronales convolucionales para la detección de patrones cerebrales asociados a la intención de iniciar o detener la marcha en sistemas de asistencia robótica. Este problema resulta clave en el desarrollo de interfaces cerebro-computador aplicadas al control de exoesqueletos, donde la identificación precisa de la intención del usuario es fundamental para garantizar un funcionamiento seguro y eficiente.

El objetivo de este trabajo es analizar el rendimiento de diferentes arquitecturas de redes neuronales convolucionales en la clasificación de señales EEG, así como evaluar distintas estrategias de entrenamiento, incluyendo modelos entrenados con datos del mismo día, enfoques acumulativos y técnicas de fine-tuning. Para ello, se emplean registros de EEG previamente adquiridos, aplicando esquemas de validación cruzada y evaluaciones en entornos pseudo-online que simulan condiciones reales de uso.

Los resultados obtenidos permiten comparar el impacto de la arquitectura, el método de entrenamiento y la variabilidad entre usuarios en el rendimiento del sistema, destacando aquellas configuraciones que maximizan la precisión y reducen los falsos positivos. Asimismo, se identifican diferencias significativas entre los distintos enfoques evaluados, lo que proporciona información relevante para el diseño de sistemas más robustos.

Finalmente, este trabajo sienta las bases para la aplicación de estos modelos en escenarios reales, contribuyendo al desarrollo de sistemas de control más fiables en exoesqueletos y otras tecnologías de asistencia basadas en interfaces cerebro-computador.

ÍNDICE

AGRADECIMIENTOS	III
RESUMEN	V
ÍNDICE DE TABLAS	XI
ÍNDICE DE FIGURAS	XII
1. Introducción	1
1.1. Definición del problema	2
1.2. Objetivos a Conseguir	2
2. Estado del Arte	4
2.1. Conceptos Relevantes del Dominio	4
2.1.1. Lesiones y patologías del sistema nervioso central	4
2.1.2. Electroencefalografía (EEG)	6
2.1.3. Interfaces Cerebro-Computador (BCI)	9
2.1.4. Redes neuronales convolucionales	11
2.2. Proyectos similares	13
2.2.1. Comparación de modelos en la literatura	13
2.2.2. Distintos entrenamientos en la literatura	14
3. Material y Métodos	18

3.1. Materiales	18
3.1.1. Hardware	18
3.1.2. Software	19
3.2. Dataset	20
3.2.1. Estructura temporal de los ensayos	21
3.2.2. Preprocesamiento	23
3.3. Modelos utilizados	24
3.3.1. DeepConvNet y ShallowConvNet	24
3.3.2. EEGNet	26
3.4. Metodología experimental	28
3.4.1. Variables del estudio	28
3.4.2. Estrategia de entrenamiento	30
3.4.3. Evaluación	31
3.5. Infraestructura Experimental	31
3.5.1. Diseño de experimentos	32
4. Resultados y Discusión	34
4.1. Tarea Estática	35
4.1.1. Comparación de Global	35
4.1.2. Comparación de Método de Entrenamiento	36
4.1.3. Variabilidad Entre Usuarios	36
4.1.4. Mejor Configuración	37

4.2. Tarea Movimiento	37
4.2.1. Comparación de Global	38
4.2.2. Comparación de Método de Entrenamiento	39
4.2.3. Variabilidad Entre Usuarios	39
4.2.4. Mejor Configuración	40
4.3. Comparación entre tareas	40
5. Conclusiones	41
5.0.1. Vías Futuras	41
BIBLIOGRAFÍA	43
ANEXOS	54
A. Primer anexo	54
B. Segundo anexo	55

ÍNDICE DE TABLAS

3.1. Arquitectura DeepConvNet utilizada.	25
3.2. Arquitectura ShallowConvNet utilizada.	26

ÍNDICE DE FIGURAS

2.1. Esquema de las lesiones medulares en función del area de lesión [9] . .	5
2.2. Esquema general del funcionamiento de una BCI [29]	10
3.1. Estructura temporal de las ventanas EEG utilizadas durante cada ensayo. Adaptado de [54].	22
3.2. Estructura jerárquica de los tensores de entrada y etiquetas utilizados en el modelo.	23
3.3. Arquitectura de EEGNet. las líneas muestran la conexión entre las capas [40].	28
3.4. Pipeline experimental	33
4.1. Comparación general de las distintas arquitecturas y métodos de entrenamiento en la tarea estática	35
4.2. Variabilidad entre usuarios en la tarea estática	36
4.3. Mejores configuraciones globales en la tarea estática	37
4.4. Comparación general de las distintas arquitecturas y métodos de entrenamiento en la tarea de movimiento	38
4.5. Variabilidad entre usuarios en la tarea de movimiento	39
4.6. Mejores configuraciones globales en la tarea de movimiento	40
4.7. Comparación de la precisión entre la tarea estática y la de movimiento	40
5.1. Ejemplo de arquitectura de control basada en una máquina de estados finitos para sistemas BCI. Tomado de [57]	42

1. Introducción

Según la Organización Mundial de la Salud (OMS), las lesiones medulares afectan a más de 15 millones de personas a nivel mundial. Estas pueden ser ocasionadas tanto por traumatismos como por causas no traumáticas, incluyendo tumores, enfermedades degenerativas y vasculares, infecciones o defectos congénitos. Como consecuencia, producen una pérdida completa o parcial de las funciones sensoriales y/o motoras por debajo del nivel de la lesión, siendo una de las principales causas de discapacidad de larga duración [1].

Las limitaciones en la movilidad derivadas de estas lesiones dificultan la participación plena en la sociedad. En adultos, esto se traduce en tasas de desempleo superiores al 60 %, mientras que en población infantil se observa una menor continuidad en el sistema educativo [1], [2].

La necesidad de abordar los problemas causados por estas lesiones ha impulsado en los últimos años el desarrollo de nuevas terapias y dispositivos de rehabilitación [3].

En este contexto, las Interfaces Cerebro-Computador (BCIs) han emergido como una tecnología prometedora para la asistencia y rehabilitación de pacientes con discapacidad motora, al permitir la comunicación directa entre la actividad cerebral y dispositivos externos. Estas interfaces emplean principalmente señales electroencefalográficas (EEG) para identificar patrones neuronales asociados a la intención de movimiento [4]. Su aplicación en sistemas de asistencia, como exoesqueletos robóticos, abre nuevas posibilidades para mejorar la autonomía y calidad de vida de personas con lesiones medulares.

Sin embargo, la interpretación de las señales EEG presenta importantes desafíos debido a su baja relación señal-ruido y a la elevada variabilidad entre sujetos y sesiones, lo que dificulta el desarrollo de modelos robustos y generalizables [5].

1.1. Definición del problema

Este trabajo aborda la clasificación de señales EEG registradas durante la imaginación activa de tareas de marcha, con el objetivo de detectar patrones cerebrales relacionados con la intención de caminar o detenerse.

El problema se enmarca en el contexto de las BCI orientadas a aplicaciones de rehabilitación, donde resulta fundamental identificar de forma fiable los estados mentales del usuario a partir de señales cerebrales no invasivas.

Para ello, se pretende evaluar la capacidad de diferentes arquitecturas de redes neuronales para extraer características discriminativas a partir de datos EEG pre-procesados, analizando su rendimiento bajo distintos esquemas de entrenamiento y validación.

Además, se estudia la capacidad de generalización de los modelos, evaluando su robustez frente a la variabilidad entre los sujetos y las diferentes sesiones de registro.

1.2. Objetivos a Conseguir

El objetivo principal de este trabajo es evaluar el rendimiento de distintas arquitecturas de redes neuronales en la clasificación de la intención de marcha del usuario a partir de señales EEG.

Para alcanzar este objetivo general, se plantean los siguientes objetivos específicos:

1. Entrenar y evaluar diferentes arquitecturas de redes neuronales

- EEGNet
- DeepConvNet
- ShallowConvNet

2. Evaluar diferentes métodos de entrenamiento

- Intra-session

- Cross-session
 - Cross-subject
 - Aprendizaje continuo
3. Analizar variabilidad entre usuarios y su efecto en el rendimiento de los modelos
 4. Evaluar el comportamiento de los modelos en diferentes escenarios de validación, incluyendo validación cruzada y entornos pseudo-online.

2. Estado del Arte

Este capítulo trata de introducir los fundamentos que sustentan este trabajo, al igual que se ahonda en el estado actual de las técnicas de Interfaz Cerebro-Computador (BCI) y Electroencephalography (EEG) y sus aplicaciones, para de esta manera poder entender el problema que se pretende resolver y la solución que se pretende dar.

2.1. Conceptos Relevantes del Dominio

En este apartado se mencionan los conceptos relevantes que se utilizan en este trabajo para proporcionar una base suficiente para entender el problema que se pretende resolver.

2.1.1. Lesiones y patologías del sistema nervioso central

El sistema nervioso central (CNS), encargado de la planificación, iniciación y modulación del movimiento, comprende estructuras como la corteza cerebral, el tronco encefálico, el cerebelo y la médula espinal. A través de estas estructuras, el CNS procesa la información sensorial y genera impulsos nerviosos que son transmitidos a los músculos para producir movimiento [6].

Las lesiones o patologías que afectan al CNS pueden dañar tanto las neuronas como las vías de comunicación entre ellas, alterando la transmisión de señales motoras y sensitivas. Como consecuencia, pueden aparecer deficiencias motoras, pérdida de sensibilidad, alteraciones del equilibrio o dificultades en la coordinación del movimiento [6].

Entre las lesiones más relevantes se encuentran las lesiones medulares (SCI), producidas por causas traumáticas o no traumáticas que dañan parcial o totalmente la médula espinal. Este daño interrumpe la transmisión de señales nerviosas entre el cerebro y las regiones corporales situadas por debajo de la lesión. Los síntomas

dependen tanto de la localización como de la gravedad del daño. Las lesiones cervicales pueden provocar tetraplegia, mientras que lesiones en regiones más bajas suelen derivar en paraplegia [7], [8].

En la figura 2.1 se puede ver un esquema de las lesiones medulares en función del area de lesión.


		Nivel de la lesión	Efecto*	
C T L S		C E R V I C A L	Entre C2 y C5	Parálisis de algunos o todos los músculos utilizados para respirar y todos los músculos de brazos y piernas. En general mortal, a menos que se use un ventilador.
		Entre C5 y C6	Parálisis de las piernas, tronco, mano y muñeca. Debilidad de los músculos que mueven el hombro y el codo.	
		Entre C6 y C7	Parálisis de las piernas, el tronco y parte de las muñecas y manos. Movimiento normal de hombros y codos.	
		Entre C7 y C8	Parálisis de las piernas, el tronco y las manos.	
		T O R Á C I C A	C8 a T1	Parálisis de piernas y tronco. Debilidad de los músculos que mueven dedos y manos. Síndrome de Horner (con párpado caído, pupila constreñida y sudoración reducida en un lado de la cara). Posiblemente movimiento normal de hombros y codos.
		T2 a T4	Parálisis de piernas y tronco. Pérdida de la sensibilidad debajo de los pezones. Movimiento normal de hombros y codos.	
		T5 a T8	Parálisis de las piernas y la parte inferior del tronco. Pérdida de la sensibilidad debajo de la caja torácica.	
		L U M B A R	T9 a T11	Parálisis de las piernas. Pérdida de la sensibilidad debajo del ombligo.
		T11 a L1	Parálisis y pérdida de sensibilidad en caderas y piernas.	
		S A C R O	L2 a S2	Diversos patrones de debilidad y entumecimiento, según el nivel concreto de la lesión.
		S3 a S5	Entumecimiento en el perineo.	
*Las lesiones graves pueden causar la pérdida del control de la vejiga y el intestino en cualquier nivel de la médula espinal.				

Figura 2.1: Esquema de las lesiones medulares en función del area de lesión [9]

Otra de las principales patologías del CNS son los accidentes cerebrovasculares o ictus. Estos pueden clasificarse en hemorrágicos, cuando se produce la rotura de un vaso sanguíneo cerebral, o isquémicos, cuando una obstrucción reduce o bloquea el flujo sanguíneo. En ambos casos se produce daño neuronal debido a la falta de

oxígeno y nutrientes en el tejido cerebral afectado [10]. Los ictus representan una de las principales causas de discapacidad motora adquirida y mortalidad a nivel mundial [6], [10], [11].

A pesar de la gravedad de estas lesiones, existe un potencial de rehabilitación en la neuroplasticidad. La neuroplasticidad es la capacidad del CNS para modificar su estructura y funcionamiento, así como crear nuevas conexiones neuronales en respuesta a estímulos externos o internos [6], [12]. La rehabilitación neurológica busca potenciar esta reorganización funcional de las áreas cerebrales no afectadas [13], creando nuevas conexiones mediante la repetición de tareas.

La rehabilitación constituye un proceso complejo que requiere un enfoque multidisciplinar y tratamientos personalizados. Aunque parte de la recuperación motora suele producirse durante los primeros meses tras la lesión, muchos pacientes continúan presentando secuelas permanentes en fases crónicas [11]. En estos casos, las tecnologías de asistencia, incluyendo los sistemas basados en interfaces cerebro-computadora (BCI), representan una herramienta prometedora para mejorar la autonomía y la interacción con el entorno.

2.1.2. Electroencefalografía (EEG)

La electroencefalografía (EEG) consiste en la captación de la actividad eléctrica cerebral generada por la comunicación entre neuronas. Estas señales se registran mediante electrodos no invasivos colocados sobre el cuero cabelludo y son posteriormente amplificadas y representadas en función del tiempo [14], [15].

Dentro de estas señales se encuentran respuestas neuronales asociadas a distintos tipos de eventos (sensoriales, cognitivos y motores) conocidas como potenciales relacionados con eventos (ERP), así como aquellas asociadas a la imaginación motora (MI) [14], [16].

Es común realizar una separación de estas señales en función de su frecuencia, ya que se ha demostrado que distintas bandas de frecuencia se corresponden con estados mentales concretos [15], [17].

- **Delta** (<4 Hz): Ubicadas en la región frontal en adultos y posterior en los niños. Se asocian principalmente al sueño, siendo también frecuentes en niños y en tareas de atención sostenida.
- **Theta** (4–7 Hz): Predominan en las regiones parietal y temporal en niños. En adultos, aparecen durante algunas fases del sueño o en estados de estrés
- **Alpha** (8–13 Hz): Se localizan en la región occipital. Se asocian a estados de relajación con los ojos cerrados, disminuyendo durante la concentración y el sueño.
- **Beta** (13–30 Hz): Son detectadas en los lóbulos frontal y parietal y presentan una distribución relativamente simétrica. Aparecen en tareas de calma activa con los ojos abiertos. Pero también pueden aparecer durante actividad mental intensa o situaciones de estrés.
- **Gamma** (>30 Hz): Se han relacionado con actividad en la región somatosensorial durante tareas de procesamiento multisensorial y en procesos cognitivos complejos, como la memoria.
- **Mu** (8–12 Hz): Se localizan en el córtex sensoriomotor y se asocian a la actividad de este sistema en reposo.

El análisis de señales EEG es una herramienta muy potente que permite revelar información sobre la actividad cerebral de un individuo, teniendo muchas aplicaciones en neurociencia y en el control de BCI [18].

Entre las principales ventajas del uso de EEG se encuentran [14], [15], [19], [20]:

- **Alta resolución temporal:** Permite registrar cambios en la actividad cerebral en el rango de milisegundos.
- **Medición directa de actividad eléctrica:** A diferencia de otras técnicas que estiman la actividad cerebral de forma indirecta mediante cambios en los niveles de oxígeno en sangre, las señales EEG registran directamente la actividad eléctrica generada por poblaciones neuronales.

- **Carácter no invasivo:** La señal puede registrarse mediante electrodos colocados sobre el cuero cabelludo, sin necesidad de procedimientos quirúrgicos. Esto reduce el riesgo de sufrir complicaciones durante la captura de la señal y las molestias a los pacientes.
- **Bajo coste relativo:** En comparación con otras técnicas de neuroimagen, como la resonancia magnética funcional, los sistemas EEG suelen ser más accesibles y fáciles de utilizar.

Algunas de las desventajas que convierten a estas señales en difíciles de analizar son las siguientes [14], [21], [22]:

- **Baja resolución espacial:** Las señales EEG no permiten localizar con precisión la fuente de actividad cerebral, ya que representan una media de múltiples fuentes de actividad neuronales.
- **Variabilidad inter-sujeto e intra-sujeto:** Existe una gran variabilidad en las señales EEG entre diferentes individuos, lo que dificulta la observación de patrones en ellas. A su vez, las propiedades estadísticas de las señales pueden variar a lo largo del tiempo, incluso para un mismo sujeto y tarea.
- **Ruido:** Las señales EEG son altamente susceptibles a artefactos, como el movimiento, la actividad muscular (EMG) o interferencias externas. Además, la amplitud de las señales EEG es muy baja en comparación con el ruido presente, lo que exige un preprocesado avanzado para eliminar el ruido y mejorar la calidad de las señales.

Estas limitaciones justifican el uso de técnicas avanzadas de procesamiento y aprendizaje automático. En los últimos años el uso de modelos de aprendizaje profundo (deep learning) ha supuesto un avance significativo, facilitando el desarrollo de aplicaciones más prácticas y reduciendo la dependencia de procesamiento manual por parte de expertos [18].

En el contexto del aprendizaje profundo (*deep learning*) surge una cuarta limitación que es la **escasez de datos** disponibles para el entrenamiento. Los algoritmos de

deep learning requieren una gran cantidad de muestras para entrenar y generalizar, lo que dificulta su aplicación en tareas con pocos ejemplos.

A diferencia de otros dominios donde pueden obtenerse grandes volúmenes de datos de forma relativamente sencilla, la adquisición de señales EEG requiere equipamiento especializado, personal cualificado y una preparación cuidadosa de cada sesión experimental. Además, la anotación de los datos suele ser costosa y dependiente del protocolo utilizado [23].

La recogida de datos EEG también presenta limitaciones logísticas, ya que las sesiones experimentales suelen requerir tiempos prolongados de preparación y ejecución, lo que dificulta la obtención de medidas consecutivas [24]. En aplicaciones BCI, este problema se ve agravado por la fatiga física y mental de los participantes, especialmente cuando se requieren múltiples ensayos o sesiones de larga duración [25].

Como consecuencia de estas limitaciones, los conjuntos de datos EEG suelen ser significativamente más reducidos que los utilizados habitualmente en otras áreas del aprendizaje profundo.

2.1.3. Interfaces Cerebro-Computador (BCI)

Una interfaz cerebro-computador (BCI) es un sistema capaz de adquirir señales cerebrales, procesarlas y traducirlas en comandos de control para un dispositivo externo, sin necesidad de utilizar las vías motoras convencionales [26], [27]. Inicialmente, las aplicaciones de estas interfaces se centraban en la asistencia y rehabilitación de pacientes con lesiones neurológicas, permitiendo restaurar o compensar parcialmente funciones motoras perdidas [27], [28].

El esquema general de las BCI se representa en la figura 2.2. En él se observan las distintas fases de las que se compone el sistema de control [27], [29], [30].

El primer paso es la adquisición de la señal cerebral, en el cual se registran se registran los potenciales eléctricos cerebrales mediante electrodos posicionados en distintas zonas de la cabeza.

Después de la adquisición de la señal, se realiza un paso de preprocesado en el cual se elimina el ruido y los posibles artefactos de la señal, como las interferencias de red. A continuación, se aplican técnicas de extracción de características con el objetivo de obtener información relevante para la clasificación de la señal. Este procesamiento puede incluir técnicas de análisis temporal, espectral o espacial, dependiendo de la aplicación considerada.

El cuarto paso es la clasificación de la señal, en el cual se utiliza un clasificador, que detecta los patrones en las características extraídas de la señal. Los patrones detectados son posteriormente traducidos en comandos de control para el dispositivo externo. Finalmente se proporciona una retroalimentación al usuario con información acerca del resultado de los comandos enviados. Esta retroalimentación puede presentarse de forma visual, auditiva o mediante la respuesta física del propio dispositivo controlado.




Figura 2.2: Esquema general del funcionamiento de una BCI [29]

Las aplicaciones de las BCI abarcan desde la sustitución o restauración de funciones perdidas debido a lesiones o enfermedades neurológicas, hasta la mejora o ampliación de las capacidades del usuario. Entre sus usos más habituales se encuentran los sistemas de comunicación para personas con parálisis, el control de dispositivos motores como sillas de ruedas, prótesis o exoesqueletos, así como sistemas de neuroestimulación destinados recuperar funciones motoras perdidas mediante el estímulo en los músculos o nervios de la zona afectada [29], [31], [32].

Las BCI pueden clasificarse en invasivas, parcialmente invasivas y no invasivas según la ubicación de los electrodos. Las BCI invasivas registran la actividad neuronal mediante electrodos implantados directamente en el cerebro, proporcionando una elevada resolución espacial y temporal a costa de requerir procedimientos quirúrgicos complejos. Las BCI parcialmente invasivas, basadas habitualmente en electrocorticografía (ECoG), sitúan los electrodos sobre la superficie cortical y representan una solución intermedia entre calidad de señal y riesgo quirúrgico. Finalmente, las BCI no invasivas utilizan sensores externos, como EEG o MEG, colocados sobre el cuero cabelludo. Aunque presentan una menor resolución espacial debido a la atenuación de la señal por los tejidos craneales, destacan por su seguridad, menor coste y facilidad de uso, siendo las más empleadas en aplicaciones clínicas y de investigación [27]-[29], [33].

En este trabajo se emplea una BCI no invasiva basada en señales EEG para detectar la intención de marcha del usuario, permitiendo su futura integración con sistemas de asistencia robótica como exoesqueletos.

2.1.4. Redes neuronales convolucionales

Las redes neuronales convolucionales (CNN) constituyen una de las arquitecturas de aprendizaje profundo más empleadas para el análisis de datos complejos. Aunque fueron desarrolladas originalmente para tareas de visión artificial, su capacidad para extraer características relevantes de manera automática y eficiente las ha convertido en una herramienta ampliamente utilizada en ámbitos como: el procesamiento de imágenes, el reconocimiento de voz, el procesamiento del lenguaje natural y, más

recientemente, el análisis de señales biomédicas como el electroencefalograma (EEG) [33]-[36].

La operación en la que se basan estas redes es la convolución, una transformación matemática que aplica pequeños filtros o *kernels* sobre la entrada para detectar patrones específicos. Cada filtro aprende durante el entrenamiento a responder a determinadas características presentes en los datos, generando como salida un conjunto de mapas de características (*feature maps*). Estos *feature maps* se vuelven progresivamente más abstractos y complejos conforme se avanza en la red, lo que le permite aprender automáticamente las características más discriminativas para la tarea de clasificación. Las capas convolucionales requieren un número significativamente menor de parámetros que las capas completamente conectadas (*fully connected*), reduciendo el coste computacional y favoreciendo la capacidad de generalización del modelo [33]-[35], [37].

Habitualmente, una CNN está formada por una sucesión de capas convolucionales y capas de reducción dimensional (*pooling*), seguidas de una o varias capas *fully connected*. Las capas convolucionales se encargan de extraer características relevantes de la señal de entrada, mientras que las capas de *pooling* reducen la dimensionalidad de las representaciones obtenidas y contribuyen a disminuir el sobreajuste. Finalmente, las capas *fully connected* utilizan las características extraídas para realizar la clasificación o regresión correspondiente [34], [38].

En el ámbito de las interfaces cerebro-computador (BCI), las CNN se han consolidado como una de las técnicas más utilizadas para la decodificación de señales EEG [18], [20], [33]. A diferencia de las imágenes, las señales EEG presentan simultáneamente una dimensión temporal y una dimensión espacial asociada a la distribución de los electrodos sobre el cuero cabelludo. Por este motivo, las arquitecturas diseñadas para EEG suelen combinar convoluciones temporales, encargadas de extraer información espectral y patrones dependientes del tiempo, con convoluciones espaciales que modelan las relaciones entre los distintos canales de la señal [33].

Tradicionalmente, los sistemas BCI basados en EEG dependían de técnicas de extracción manual de características combinadas con clasificadores convencionales. Sin

embargo, la aparición de arquitecturas de redes neuronales profundas específicas para EEG, como DeepConvNet y ShallowConvNet, supuso un cambio de paradigma al integrar de forma conjunta las etapas de extracción de características y clasificación dentro de una misma red neuronal [20], [39].

2.2. Proyectos similares

2.2.1. Comparación de modelos en la literatura

El uso de técnicas de aprendizaje profundo para el análisis de señales EEG ha experimentado un crecimiento significativo durante la última década. Este incremento ha motivado la aparición de numerosos trabajos orientados a comparar distintas arquitecturas de redes neuronales, así como a evaluar su capacidad de generalización en diferentes paradigmas BCI, conjuntos de datos y protocolos experimentales.

Uno de los trabajos más influyentes en este ámbito es el realizado por Schirrmester et al. [20], quienes introdujeron las arquitecturas DeepConvNet y ShallowConvNet para la clasificación de señales EEG. Además de proponer ambas redes, los autores realizaron una comparación frente a métodos clásicos basados en extracción manual de características, como Filter Bank Common Spatial Patterns (FBCSP), demostrando que las arquitecturas convolucionales eran capaces de alcanzar resultados comparables o superiores sin necesidad de diseñar manualmente las características relevantes de la señal. Este trabajo supuso uno de los primeros éxitos significativos del aprendizaje profundo aplicado a sistemas BCI.

Posteriormente, Lawhern et al. [40] propusieron EEGNet, una arquitectura compacta diseñada específicamente para señales EEG. A diferencia de otros modelos convolucionales más profundos, EEGNet está enfocada en reducir significativamente el número de parámetros entrenables. Los autores demostraron que era posible obtener resultados competitivos en diferentes paradigmas BCI utilizando modelos considerablemente más ligeros, facilitando su aplicación en escenarios con recursos computacionales limitados o conjuntos de datos reducidos.

Köllöd et al. [39] desarrollaron un estudio exhaustivo sobre diferentes modelos de aprendizaje profundo aplicados a EEG. Entre las arquitecturas evaluadas se encontraban EEGNet, DeepConvNet y ShallowConvNet, además de otros modelos recientes. Los autores analizaron no sólo el efecto de la arquitectura utilizada, sino también el impacto de distintas estrategias de entrenamiento, incluyendo enfoques dependientes del sujeto y métodos basados en transferencia de aprendizaje. Sus resultados mostraron que no existe una arquitectura claramente superior para todos los conjuntos de datos y escenarios experimentales, observándose una fuerte dependencia tanto del protocolo de entrenamiento como de las características específicas de cada tarea.

La conclusión anterior coincide con las observaciones recogidas en diversas revisiones bibliográficas sobre aprendizaje profundo aplicado a EEG, como los de Craik et al. [18] y Roy et al. [41]. Estos trabajos destacan que las diferencias de rendimiento entre arquitecturas suelen depender en gran medida del conjunto de datos utilizado, del paradigma BCI considerado y del protocolo experimental empleado. Asimismo, coinciden en la ausencia de una arquitectura universalmente superior y recalcan la necesidad de utilizar benchmarks comunes que permitan realizar comparaciones más rigurosas entre arquitecturas.

En conjunto, la literatura actual sugiere que tanto la arquitectura seleccionada como la estrategia de entrenamiento empleada desempeñan un papel fundamental en el rendimiento final de los sistemas BCI basados en EEG. Por este motivo, en el presente trabajo se evalúan tres de las arquitecturas convolucionales más utilizadas en la literatura (EEGNet, DeepConvNet y ShallowConvNet) junto con diferentes estrategias de entrenamiento.

2.2.2. Distintos entrenamientos en la literatura

Según Wan et al. [42], las diferencias inter-sujeto y la escasez de datos constituyen dos de los principales obstáculos para el desarrollo de sistemas BCI basados en aprendizaje profundo. Como consecuencia, numerosas investigaciones han propuesto distintas estrategias de transferencia y reutilización del conocimiento con el objetivo

de mejorar la generalización de los modelos EEG.

Entrenamiento intra-sesión

El entrenamiento intra-sesión constituye el enfoque tradicional en sistemas BCI. En este escenario, el modelo se entrena y evalúa utilizando únicamente datos obtenidos durante una misma sesión del usuario. Este planteamiento minimiza el impacto de la variabilidad temporal y entre sujetos, permitiendo obtener una alta precisión para la sesión concreta utilizada durante el entrenamiento.

Ma et al. [43] propusieron un benchmark intra-sesión en el que los datos de cada sesión eran divididos aleatoriamente en conjuntos de entrenamiento, validación y test siguiendo una proporción 8:1:1. La evaluación final se realizaba mediante validación cruzada de 10 particiones. Este protocolo fue utilizado para comparar diferentes arquitecturas de aprendizaje profundo, entre ellas EEGNet, DeepConvNet y ShallowConvNet.

A pesar de proporcionar buenos resultados, este tipo de entrenamiento presenta una importante limitación práctica: requiere una nueva fase de calibración para cada sesión del usuario, dificultando su utilización en aplicaciones reales de larga duración, como mencionan Sung et al. [44].

Transferencia entre sesiones

Con el objetivo de reducir la necesidad de re-entrenar el modelo para cada sesión, diversos autores han estudiado estrategias que aprovechan información procedente de sesiones anteriores del mismo usuario.

En el benchmark cross-sesión propuesto por Ma et al. [43], los datos de la primera sesión de cada sujeto se utilizaron para el entrenamiento, mientras que las cuatro sesiones restantes se emplearon para evaluación. Este protocolo permite cuantificar el impacto de la variabilidad temporal de las señales EEG sobre el rendimiento de los clasificadores.

Posteriormente, Sung et al. [44] compararon diferentes estrategias de transferencia entre sesiones. Entre ellas destaca el método *Whole Session Transfer* (WST), que incorpora todas las sesiones anteriores al conjunto de entrenamiento de la sesión actual. Los autores observaron que este enfoque obtenía mejores resultados que el entrenamiento exclusivamente intra-sesión. Además, propusieron una estrategia denominada *Relevant Session Transfer* (RST), basada en la selección de sesiones previas mediante medidas de similitud, obteniendo mejoras adicionales en la precisión de clasificación.

De forma similar, Wu et al. [45] identifican la transferencia cross-sesión como uno de los principales escenarios de *transfer learning* en sistemas EEG, donde los datos de sesiones previas son utilizados para facilitar la calibración de nuevas sesiones del mismo usuario.

Transferencia entre sujetos

Otra línea de investigación busca reducir la dependencia de datos específicos del usuario mediante la utilización de información procedente de otros participantes.

Según la clasificación propuesta por Wu et al. [45], el escenario *cross-subject* utiliza datos de varios sujetos como dominios fuente para facilitar la calibración de un nuevo usuario. Este enfoque resulta especialmente interesante debido a que permite disminuir significativamente el tiempo necesario para la adquisición de datos de calibración.

Diversos trabajos recientes han explorado estrategias de adaptación basadas en modelos pre-entrenados con múltiples usuarios y posteriormente ajustados mediante *fine-tuning* utilizando una cantidad reducida de datos del sujeto objetivo Otarbay y Kyzzyrkanov [46] y An et al. [47]. Estos métodos han demostrado que es posible aprovechar conocimiento adquirido en otros usuarios para mejorar el rendimiento inicial de los sistemas BCI.

Aprendizaje continuo y adaptación progresiva

Más recientemente, varios autores han estudiado estrategias de adaptación progresiva en las que el modelo incorpora nueva información conforme se dispone de sesiones adicionales del usuario.

Lu et al. [48] proponen un procedimiento basado en el entrenamiento inicial de un modelo general utilizando datos fuente y posteriormente su adaptación mediante *fine-tuning* con datos específicos del usuario objetivo. Por su parte, Wimpff et al. [49] demostraron que la adaptación progresiva utilizando únicamente datos disponibles antes de cada sesión de evaluación permite mejorar tanto la precisión como la estabilidad del sistema a lo largo del tiempo.

Este tipo de enfoques se encuentra estrechamente relacionado con el aprendizaje continuo (*continual learning*), cuyo objetivo es incorporar nueva información preservando simultáneamente el conocimiento previamente adquirido y reduciendo el problema de la pérdida de rendimiento en sesiones largas (Huang et al. [50]). En esta misma línea, Abu-Rmileh et al. [51] propusieron un mecanismo de actualización periódica del clasificador utilizando los datos de los dos ensayos anteriores del usuario para adaptar progresivamente el modelo durante varios días de uso.

Las estrategias descritas anteriormente constituyen la base de los distintos métodos de entrenamiento evaluados en este trabajo, los cuales buscan estudiar el impacto del método de transferencia sobre el rendimiento de modelos convolucionales aplicados a señales EEG.

3. Material y Métodos

3.1. Materiales

3.1.1. Hardware

Para ejecutar los distintos entrenamientos se ha utilizado un ordenador con las siguientes características:

- **CPU:** Intel Core i9-14900HX
- **RAM:** 31 GiB
- **GPU:** NVIDIA GeForce RTX 4060
- **GPU RAM:** 8 GiB

Estas características han resultado suficientes para completar los experimentos planteados sin limitaciones críticas. El tiempo medio de entrenamiento por iteración ha sido aproximadamente 40 minutos, dependiendo de la configuración del modelo y de los parámetros de entrenamiento.

El tiempo total de cómputo se estima mediante:

$$\text{Tiempo total (h)} = \frac{N_{\text{iteraciones}} \times t_{\text{iteración}}}{60}$$

Donde $N_{\text{iteraciones}} = 1917$ y $t_{\text{iteración}} = 40\text{minutos}$, resultando en un tiempo total aproximado de 766.8 horas ($\approx 31\text{días}$).

El uso de hardware con mayores prestaciones permitiría reducir significativamente el tiempo total de entrenamiento y facilitar la realización de un mayor número de experimentos.

3.1.2. Software

Para el desarrollo del proyecto se ha utilizado una infraestructura basada en herramientas ampliamente empleadas en el ámbito del aprendizaje automático y la ingeniería de software.

Como lenguaje de programación principal se ha utilizado Python¹, debido a su amplio ecosistema de librerías científicas y de aprendizaje automático, así como su facilidad de integración con frameworks de alto nivel.

Para la construcción y entrenamiento de los modelos se han utilizado TensorFlow² y Keras³, frameworks de aprendizaje profundo que permiten definir, entrenar y evaluar redes neuronales de forma eficiente. Keras se ha empleado como interfaz de alto nivel sobre TensorFlow, facilitando la experimentación rápida con distintas arquitecturas.

Durante las etapas iniciales del proyecto se empleó Jupyter Notebook⁴ para la realización de pruebas exploratorias y la visualización preliminar de resultados. Sin embargo, su uso fue descartado en fases posteriores debido a la dificultad para mantener una estructura de código modular y escalable en experimentos de mayor complejidad.

Posteriormente, se adoptó Visual Studio Code⁵ como entorno de desarrollo principal, debido a su capacidad para gestionar múltiples tipos de archivos y su integración con herramientas de desarrollo. Se utilizaron extensiones específicas para Python, Jupyter y GitHub, permitiendo un flujo de trabajo unificado.

Como sistema de control de versiones se ha utilizado GitHub⁶, que facilita la gestión del código, el seguimiento de cambios y la colaboración con el tutor del proyecto. Además, permite la sincronización del repositorio entre distintos dispositivos de forma eficiente.

¹<https://www.python.org/>

²<https://www.tensorflow.org/>

³<https://keras.io/>

⁴<https://jupyter.org/>

⁵<https://code.visualstudio.com/>

⁶<https://github.com/>

Para la visualización de resultados se ha utilizado Vega-Altair⁷, una librería de visualización estadística declarativa enfocada en la simplicidad, eficiencia y legibilidad. A diferencia de enfoques imperativos como Matplotlib, Altair permite definir visualizaciones de forma estructurada y reproducible, enfocándose en lo que se quiere observar en lugar de en los detalles de la implementación. Esto conduce a un código más limpio y legible [52]

Como gestor de base de datos se ha utilizado DuckDB⁸, un sistema de bases de datos analítico embebido que permite realizar consultas SQL de forma eficiente directamente sobre archivos locales. Su integración con Python y su alto rendimiento lo hacen especialmente adecuado para el procesamiento de grandes volúmenes de resultados experimentales [53].

Todas estas herramientas han sido integradas en un flujo de trabajo unificado orientado a la ejecución reproducible de experimentos.

3.2. Dataset

El dataset utilizado en este trabajo está compuesto por registros EEG obtenidos de 5 sujetos a lo largo de 5 días consecutivos de adquisición. Para cada día se realizaron 11 ensayos (*trials*), y cada ensayo fue segmentado en 56 ventanas temporales, obteniendo un total de:

$$5 \times 5 \times 11 \times 56 = 15400 \text{ ventanas}$$

Cada ventana contiene 400 muestras adquiridas a una frecuencia de muestreo de 200 Hz, lo que equivale a 2 segundos de señal EEG.

Las Muestras a su vez incluyen la señal de 27 canales EEG. Los 27 canales corresponden a los electrodos seleccionados para la adquisición de la señal. Por tanto, cada instancia del dataset puede interpretarse como una matriz de tamaño 27×400 , donde cada fila representa la evolución temporal de un canal EEG durante la ventana

⁷<https://altair-viz.github.io/>

⁸<https://duckdb.org/>

analizada.

Los 27 canales EEG utilizados fueron: F3, FZ, FC1, FCZ, C1, CZ, CP1, CPZ, FC5, FC3, C5, C3, CP5, CP3, P3, PZ, F4, FC2, FC4, FC6, C2, C4, CP2, CP4, C6, CP6 y P4. Estos electrodos se colocaron siguiendo el sistema internacional 10-10 [54].

Los datos originales se encuentran distribuidos en cuatro ficheros MATLAB diferenciados según la tarea experimental:

	Labels	Training
Static	labels_static_data.mat	training_static_data.mat
Motion	labels_motion_data.mat	training_motion_data.mat

Los ficheros de etiquetas contienen la intención de movimiento asociada a cada ventana temporal, mientras que los ficheros de entrenamiento almacenan las señales EEG correspondientes.

Las etiquetas presentan una dimensión $(15400, 1)$, mientras que los datos EEG poseen una estructura $(15400, 27, 400)$, donde:

- $N = 15400$ corresponde al número total de ventanas,
- $C = 27$ representa el número de canales EEG,
- $S = 400$ indica el número de muestras temporales por ventana.

3.2.1. Estructura temporal de los ensayos

Cada *trial* corresponde a una secuencia estructurada de tareas mentales compuesta por tres etapas:

- 14 ventanas de relajación inicial (7s),
- 28 ventanas de imaginación motora de la marcha (14s),
- 14 ventanas finales de relajación (7s).

Las ventanas se organizan secuencialmente dentro de cada ensayo con un desplazamiento temporal de 0.5s entre ventanas consecutivas.

Antes de cada tarea mental se le da una instrucción al usuario, esta instrucción puede alterar el clasificador, ya que no corresponde con ninguna tarea mental definida, por lo que se eliminan durante el preprocesamiento.

Adicionalmente, antes de cada ensayo se incluía un periodo inicial de duración aleatoria en el que el sujeto realizaba una tarea mental distinta. El objetivo de este periodo es el de reducir artefactos y ruido en la señal (convergencia de filtros). Este segmento fue eliminado durante el procesamiento previo del dataset.

Durante las sesiones experimentales los sujetos alternaban entre las tareas de imaginación de parada (*static*) y de imaginación de movimiento (*motion*) con el objetivo de reducir la fatiga y evitar la monotonía durante la adquisición.

La Figura 3.1 muestra un esquema de la segmentación temporal empleada durante los ensayos.




Figura 3.1: Estructura temporal de las ventanas EEG utilizadas durante cada ensayo. Adaptado de [54].

3.2.2. Preprocesamiento

Previo al estudio, las señales EEG fueron sometidas a una etapa de preprocesamiento con el objetivo de reducir el ruido y conservar únicamente los componentes frecuenciales relevantes para las tareas mentales objetivo.

En concreto, a cada canal EEG se le aplicó un filtro paso banda entre 8 y 40 Hz. Este rango frecuencial incluye principalmente las bandas μ (8–13 Hz) y β (13–30 Hz), ampliamente utilizadas en aplicaciones de BCI basadas en imaginación motora debido a su relación con la actividad cortical motora [55].

A partir de los datos preprocesados, se ha realizado una reorganización estructural de los mismos con el objetivo de facilitar su uso en los modelos propuestos. En concreto, los datos se han reestructurado en tensores de seis dimensiones:

Con el objetivo de facilitar el entrenamiento y evaluación de los modelos propuestos, los datos fueron reorganizados en tensores que preservan la jerarquía original del dataset.

Los tensores de entrada y etiquetas presentan las siguientes dimensiones:

Input tensor shape: (5, 5, 11, 56, 27, 400)						
Dim.	1	2	3	4	5	6
Name	Users	Days	Trials	Windows	Channels	Samples
Size	5	5	11	56	27	400
Labels tensor shape: (5, 5, 11, 56, 1)						
Dim.	1	2	3	4	5	
Name	Users	Days	Trials	Windows	Label	
Size	5	5	11	56	1	

Figura 3.2: Estructura jerárquica de los tensores de entrada y etiquetas utilizados en el modelo.

Esta organización permite mantener la coherencia temporal y experimental de las muestras durante las distintas fases de entrenamiento y evaluación.

En cuanto a la partición de los datos, se ha realizado una división entrenamiento-test

con una proporción del 70 % y 30 %, respectivamente. Esta separación se ha llevado a cabo a nivel de *trial*, evitando separar ventanas pertenecientes al mismo ensayo entre ambos conjuntos.

La selección del conjunto de test no se ha realizado de forma aleatoria, sino utilizando los últimos *trials* de cada sujeto y día. Esta decisión se basa en la hipótesis de que los sujetos presentan una mejora progresiva en el control de la imaginación motora a lo largo de la sesión, lo que permite evaluar el modelo en condiciones más estables.

Finalmente, no se aplicaron técnicas adicionales de filtrado o procesamiento sobre las señales EEG.

3.3. Modelos utilizados

Se van a definir las arquitecturas de los modelos usados en el estudio y a justificar su elección.

3.3.1. DeepConvNet y ShallowConvNet

Las arquitecturas DeepConvNet y ShallowConvNet, propuestas por Schirrmeyer et al. [20], fueron de los primeros modelos convolucionales en lograr un impacto significativo en la clasificación de señales EEG. Desde entonces, estas arquitecturas han sido ampliamente utilizadas como referencia en numerosos trabajos relacionados con interfaces cerebro-computador y Deep Learning aplicado a EEG [39].

La arquitectura DeepConvNet está formada por cuatro bloques convolucionales seguidos de operaciones de *max-pooling* y una capa final de clasificación *softmax*. El primer bloque convolucional fue diseñado específicamente para adaptarse a las características de las señales EEG, las cuales presentan un número elevado de canales de entrada correspondientes a los distintos electrodos. Para ello, el bloque es separado en dos capas. La primera realiza un filtrado temporal sobre la señal de cada canal, permitiendo extraer patrones relacionados con las frecuencias presentes en el EEG. Posteriormente, la segunda convolución aplica un filtrado espacial combinando la

información obtenida en la primera capa. Esta separación entre convolución temporal y espacial actúa además como una forma implícita de regularización, forzando a la red a aprender transformaciones más estructuradas [20].

Block	Layer	# filters	Size	# params	Output
1	Input	—	—	0	(27, 400, 1)
	Conv2D	25	(1, 8)	225	(27, 393, 25)
	Conv2D	25	(27, 1)	16900	(1, 393, 25)
	BatchNorm	—	—	100	(1, 393, 25)
	Activation	—	ELU	0	(1, 393, 25)
	MaxPool2D	—	(1, 2)	0	(1, 196, 25)
	Dropout	—	—	0	(1, 196, 25)
2	Conv2D	50	(1, 8)	10050	(1, 189, 50)
	BatchNorm	—	—	200	(1, 189, 50)
	Activation	—	ELU	0	(1, 189, 50)
	MaxPool2D	—	(1, 2)	0	(1, 94, 50)
	Dropout	—	—	0	(1, 94, 50)
3	Conv2D	100	(1, 8)	40100	(1, 87, 100)
	BatchNorm	—	—	400	(1, 87, 100)
	Activation	—	ELU	0	(1, 87, 100)
	MaxPool2D	—	(1, 2)	0	(1, 43, 100)
	Dropout	—	—	0	(1, 43, 100)
4	Conv2D	200	(1, 8)	160200	(1, 36, 200)
	BatchNorm	—	—	800	(1, 36, 200)
	Activation	—	ELU	0	(1, 36, 200)
	MaxPool2D	—	(1, 2)	0	(1, 18, 200)
	Dropout	—	—	0	(1, 18, 200)
	Flatten	—	—	0	(3600)
Classifier	Dense	—	—	7202	(2)
	Activation	—	softmax	0	(2)

Tabla 3.1: Arquitectura DeepConvNet utilizada.

Por otro lado, la arquitectura ShallowConvNet fue diseñada específicamente para la clasificación de características de la potencia de banda. Su estructura busca aproximarse al funcionamiento del método FBCSP mediante operaciones equivalentes implementadas mediante capas convolucionales. Al igual que DeepConvNet, las primeras capas realizan convoluciones temporales y espaciales. Sin embargo, en este caso la convolución temporal utiliza kernels de mayor tamaño con el objetivo de capturar mejor la información frecuencial de la señal.

Después de estas convoluciones, ShallowConvNet incorpora una secuencia de operaciones compuesta por una *no linealidad cuadrática*, una capa de *mean-pooling* y una activación logarítmica. Este conjunto de transformaciones es análogo al cálculo

de la varianza logarítmica utilizado tradicionalmente en FBCSP. Además, el uso de múltiples regiones de *pooling* dentro de un mismo ensayo permite a la red aprender variaciones temporales de la potencia de banda a lo largo del tiempo [20].

Block	Layer	# filters	Size	# params	Output
1	Input	–	–	0	(27, 400, 1)
	Conv2D	40	(1, 20)	840	(27, 381, 40)
	Conv2D	40	(27, 1)	43200	(1, 381, 40)
	BatchNorm	–	–	160	(1, 381, 40)
	Activation	–	square	0	(1, 381, 40)
	AveragePool2D	–	(1, 60)	0	(1, 27, 40)
	Activation	–	log	0	(1, 27, 40)
	Dropout	–	$p = 0,4$	0	(1, 27, 40)
	Flatten	–	–	0	(1080)
Classifier	Dense	–	–	2162	(2)
	Activation	–	softmax	0	(2)

Tabla 3.2: Arquitectura ShallowConvNet utilizada.

Las Tablas 3.2 y 3.1 muestran las configuraciones específicas de las arquitecturas ShallowConvNet y DeepConvNet utilizadas en este trabajo. En ambos casos, se adaptaron los parámetros originales propuestos por Schirrmeister et al. [20] para ajustarse a las características del conjunto de datos empleado, compuesto por señales EEG de 27 canales y ventanas temporales de 400 muestras.

Puede observarse que ShallowConvNet está formada por un único bloque convolucional seguido de las operaciones de agrupamiento y clasificación, mientras que DeepConvNet emplea una estructura jerárquica compuesta por cuatro bloques convolucionales sucesivos, incrementando progresivamente el número de filtros y la capacidad de representación del modelo.

Los resultados obtenidos por Schirrmeister et al. mostraron que estas arquitecturas alcanzaban resultados comparables a métodos clásicos como Filter Bank Common Spatial Pattern (FBCSP) [20], [33].

3.3.2. EEGNet

EEGNet es un modelo de red neuronal convolucional (CNN) diseñado específicamente para la clasificación de señales EEG. Su arquitectura se basa en el uso de

convoluciones *Depthwise* y *Separable*, ampliamente utilizadas en tareas de clasificación de imágenes, adaptándolas al procesamiento de señales EEG. Este enfoque permite extraer características espaciales y temporales de forma eficiente, utilizando conceptos como el filtrado espacial y la construcción de bancos de filtros [40].

Las características principales de este modelo son:

- Independencia respecto al paradigma BCI, permitiendo su aplicación en distintos tipos de señales EEG.
- Menor número de parámetros en comparación con otros modelos de CNN.
- Buena capacidad de generalización incluso con conjuntos de datos limitados.
- Arquitectura compacta con técnicas de regularización integradas, como *Batch Normalization* y *Dropout*.

El modelo comienza con una capa convolucional temporal encargada de extraer información frecuencial de la señal EEG. Posteriormente, se aplica una convolución *Depthwise* que aprende filtros espaciales específicos para cada mapa de características. A continuación, la arquitectura utiliza una convolución *Separable*, compuesta por una convolución *Depthwise* seguida de una convolución *Pointwise*. La primera resume temporalmente cada mapa de características de manera independiente, mientras que la segunda combina la información obtenida entre los distintos mapas de características [40]. El esquema de esta arquitectura se muestra en la figura 3.3.

Finalmente, el modelo se entrena utilizando el optimizador Adam y minimizando la función de pérdida de entropía cruzada categórica.

Estudios posteriores han mostrado que EEGNet es capaz de aprender representaciones similares a las obtenidas mediante métodos clásicos de extracción de características, como Filter Bank Common Spatial Patterns (FBCSP), manteniendo la ventaja de realizar dicho proceso de forma automática dentro de la propia red neuronal. Finalmente, esta arquitectura ha mostrado buenos resultados al clasificar potenciales en la señal EEG relacionados con el movimiento (MRCP) [39], [40].




Figura 3.3: Arquitectura de EEGNet. las líneas muestran la conexión entre las capas [40].

La elección de este modelo se debe principalmente a su arquitectura compacta y a su capacidad para obtener buenos resultados incluso con conjuntos de datos reducidos, una situación habitual en aplicaciones basadas en EEG. Además, el uso de convoluciones *Depthwise* y *Separable* permite reducir significativamente el número de parámetros del modelo respecto a otras arquitecturas convolucionales, disminuyendo así el coste computacional del entrenamiento [40].

3.4. Metodología experimental

3.4.1. Variables del estudio

En este trabajo se realiza un análisis comparativo entre las arquitecturas *EEGNet*, *ShallowConvNet* y *DeepConvNet*. Para ello, se han definido cuatro estrategias de entrenamiento con el objetivo de evaluar cómo se adapta cada modelo a diferentes usuarios, sesiones y condiciones experimentales.

Las tareas de imaginación motora consideradas son la imaginación de movimiento y la imaginación de parada. En la primera, el sujeto realiza un esfuerzo mental activo orientado a iniciar o mantener el movimiento del exoesqueleto. En la segunda, el sujeto realiza un esfuerzo mental activo orientado a detener dicho movimiento.

Las estrategias de entrenamiento seleccionadas se basan en los paradigmas descritos previamente en la sección 2.2.2.

Entrenamiento intra sesión

En esta estrategia se utilizan únicamente los datos de una sesión concreta y de un único usuario. Los ensayos de dicha sesión se dividen en conjuntos de entrenamiento y validación siguiendo una proporción del 70 % y 30 %, respectivamente. Para la validación se emplean siempre los últimos ensayos de la sesión.

Esta elección se basa en la hipótesis de que los sujetos pueden presentar una mejora progresiva en el control de la imaginación motora a lo largo de la sesión. Por tanto, evaluar el modelo sobre los últimos ensayos permite analizar su rendimiento en una fase potencialmente más estable de la tarea.

Entrenamiento entre sesiones

En este caso, el modelo se entrena utilizando los datos de las sesiones anteriores del mismo usuario. A estos datos se añaden los ensayos de entrenamiento de la sesión actual, manteniendo la misma división del 70 % para entrenamiento y 30 % para validación.

Esta estrategia permite evaluar si la información acumulada de sesiones previas mejora la adaptación del modelo a una nueva sesión del mismo usuario.

Entrenamiento entre usuarios

En esta estrategia se genera inicialmente un modelo general entrenado con los datos del resto de usuarios, excluyendo al usuario objetivo. Posteriormente, dicho modelo se ajusta mediante *fine-tuning* utilizando los datos de entrenamiento de la sesión actual del usuario objetivo, manteniendo la misma proporción de entrenamiento y validación descrita anteriormente.

Este proceso se repite para todas las sesiones del usuario, generando un nuevo modelo adaptado para cada una de ellas. El objetivo de esta estrategia es analizar si un modelo preentrenado con datos de otros usuarios puede transferir conocimiento útil al usuario objetivo.

Entrenamiento continuo

El entrenamiento continuo sigue un esquema similar al entrenamiento entre usuarios, partiendo también de un modelo general entrenado con los datos del resto de usuarios. Sin embargo, en lugar de generar un nuevo modelo independiente para cada sesión, el modelo se conserva entre sesiones y se reentrena progresivamente con los datos disponibles de la sesión actual.

De este modo, el modelo incorpora de forma acumulativa la información del usuario objetivo, partiendo de un conocimiento inicial obtenido a partir del resto de usuarios y adaptándose gradualmente a sus sesiones sucesivas.

3.4.2. Estrategia de entrenamiento

epochs

batch size

callbacks:

early stopping

reduce LR

función de pérdida

métrica (accuracy)

3.4.3. Evaluación

validación cruzada

pseudo-online

explicar qué significa pseudo-online

3.5. Infraestructura Experimental

El elevado numero de ejecuciones requeridas para el estudio, hizo que, durante las etapas iniciales, se tomara la decisión de enfocar el proyecto de manera horizontal, preparando una base de ejecución sobre la cual modificar facilmente todo lo necesario para cada ejecución y permitiendo ejecutar multiples experimentos de manera secuencial.

Para lograr esto, se ha definido un pipeline de ejecución que permite realizar múltiples experimentos de forma iterativa y automatizada. Este pipeline está compuesto por distintos módulos encargados de gestionar el preprocesamiento de los datos, la configuración de los modelos, el entrenamiento y la evaluación de los mismos.

Con el objetivo de facilitar la reproducibilidad y la exploración sistemática de parámetros, el código se ha estructurado como un microframework que permite modificar de forma sencilla las variables de estudio, así como controlar la ejecución de los experimentos.

Para organizar la ejecución, se ha definido una estructura jerárquica en tres niveles:

- **Experimento:** nivel superior que agrupa el conjunto completo de configuraciones evaluadas. Un experimento consiste en la ejecución sistemática de múltiples combinaciones de parámetros.
- **Iteración:** cada una de las ejecuciones individuales del pipeline dentro de un experimento, asociada a una combinación específica de parámetros (arquitectura, método de entrenamiento y tipo de tarea).

- **Entrenamiento:** nivel más bajo de la jerarquía, correspondiente al entrenamiento y evaluación de un modelo para un usuario y sesión concretos dentro de una iteración.

De este modo, cada experimento está compuesto por múltiples iteraciones, y cada iteración incluye varios entrenamientos, uno por cada usuario y sesión del dataset. Los experimentos se definen mediante la combinación de distintos parámetros, entre los que destacan el tipo de tarea, la arquitectura del modelo y el método de entrenamiento. Para cada combinación se ejecuta una iteración independiente

En cada iteración, el sistema inicializa los parámetros de entrenamiento y carga el conjunto de datos correspondiente al tipo de tarea. A continuación, se ejecuta el método de entrenamiento seleccionado, en el que se itera sobre los distintos usuarios y sesiones disponibles en el dataset. Para cada caso, se inicializa el modelo, se realiza el entrenamiento y se evalúa su rendimiento.

Finalmente, los resultados obtenidos, junto con los parámetros utilizados, se almacenan de forma estructurada, permitiendo su posterior análisis.

Este proceso permite realizar un gran número de experimentos de manera secuencial y facilita el posterior estudio de los resultados obtenidos por cada combinación de parámetros definida.

La Figura 3.4 resume la organización jerárquica del pipeline experimental.

3.5.1. Diseño de experimentos

combinaciones de parámetros nº de ejecuciones cómo comparas resultados




Figura 3.4: Pipeline experimental

4. Resultados y Discusión

Los resultados obtenidos durante la experimentación se han almacenado en una base de datos DuckDB, tal y como se describió en la Sección 3.5. Las tablas generadas contienen, para cada ejecución realizada, tanto los metadatos asociados al entrenamiento como las métricas obtenidas durante su evaluación.

Con el objetivo de reducir la influencia de posibles valores atípicos (*outliers*) sobre el análisis estadístico, se han creado vistas derivadas de cada tabla en las que se eliminan aquellos registros cuyos valores de *accuracy* se encuentran fuera de un intervalo de tres desviaciones estándar respecto a la media. Este procedimiento, basado en el método *Z-Score* [56], se define como:

$$z = \frac{x - \mu}{\sigma}$$

donde x representa el valor analizado, μ la media de la distribución y σ la desviación estándar. De esta forma, se consideran valores atípicos aquellos que cumplen:

$$|z| > 3$$

Además, también se han eliminado aquellos registros correspondientes a entrenamientos incompletos o interrumpidos, con el fin de garantizar la consistencia de los resultados analizados.

Tras aplicar este proceso de filtrado, el número total de registros válidos quedó reducido de la siguiente manera:

- Tabla de entrenamientos: de 1917 registros originales se eliminaron 105, obteniéndose un total de 1812 registros válidos.
- Tabla de trials: de 5751 registros originales se eliminaron 515, obteniéndose un total de 5246 registros válidos.

- Tabla de clases: de 15336 registros originales se eliminaron 3331, obteniéndose un total de 12605 registros válidos.

En esta sección se presentarán estos resultados, los cuales se discutirán y analizarán siguiendo la siguiente metodología:

Primero se analizarán los resultados obtenidos por cada modelo en función de la tarea

4.1. Tarea Estática

4.1.1. Comparación de Global




Figura 4.1: Comparación general de las distintas arquitecturas y métodos de entrenamiento en la tarea estática

Me da igual todo, solo me centro en los modelos. hago avg y std con los metodos y los usuarios

4.1.2. Comparación de Método de Entrenamiento

Me da igual todo, solo me centro en los metodos. hago avg y std con los modelos y los usuarios

4.1.3. Variabilidad Entre Usuarios




Figura 4.2: Variabilidad entre usuarios en la tarea estática

4.1.4. Mejor Configuración




Figura 4.3: Mejores configuraciones globales en la tarea estática

4.2. Tarea Movimiento

mismo esquema

4.2.1. Comparación de Global




Figura 4.4: Comparación general de las distintas arquitecturas y métodos de entrenamiento en la tarea de movimiento

4.2.2. Comparación de Método de Entrenamiento

4.2.3. Variabilidad Entre Usuarios




Figura 4.5: Variabilidad entre usuarios en la tarea de movimiento

4.2.4. Mejor Configuración




Figura 4.6: Mejores configuraciones globales en la tarea de movimiento

4.3. Comparación entre tareas




Figura 4.7: Comparación de la precisión entre la tarea estática y la de movimiento

5. Conclusiones

en función de los resultados obtenidos, se expondrán las conclusiones de la investigación y se propondrán trabajos futuros.

La literatura reciente muestra que el rendimiento de las arquitecturas profundas para EEG depende significativamente del conjunto de datos y de la estrategia de entrenamiento empleada, por lo que resulta necesario evaluar distintos modelos bajo las condiciones específicas de cada aplicación [39].

5.0.1. Vías Futuras

Una posible línea de trabajo futuro consiste en integrar dos modelos distintos dentro de un mismo sistema de control, con el objetivo de aprovechar las dos tareas de imaginación motora para construir una BCI de bucle cerrado basada en una máquina de estados finitos. Este enfoque permitiría controlar de forma independiente el comportamiento del exoesqueleto y proporcionar al usuario un mayor grado de autonomía durante la interacción.

En este planteamiento, el sistema comenzaría en un estado de **parada**, en el que el exoesqueleto permanecería inmóvil mientras un modelo entrenado sobre la tarea estática (*Modelo de Inicio de la Marcha*) monitoriza continuamente la actividad cerebral del usuario. Cuando dicho modelo detectase una intención de inicio de la marcha, el sistema realizaría una transición al estado de **movimiento**.

Durante este segundo estado, el exoesqueleto ejecutaría la marcha asistida mientras un modelo entrenado sobre la tarea en movimiento (*Motion Model*) analiza la señal EEG en busca de una intención de detención. Una vez detectada esta intención, el sistema regresaría al estado de **parada**, completando así el ciclo de control.

Con el objetivo de reducir la probabilidad de falsos positivos, las predicciones de ambos modelos podrían combinarse mediante una estrategia basada en una media ponderada. De esta forma, aunque cada estado disponga de un clasificador principal,

la decisión final tendría en cuenta la información proporcionada por ambos modelos, aumentando potencialmente la robustez del sistema frente a errores de clasificación.

La Figura 5.1 muestra una representación conceptual de esta máquina de estados finitos y de las transiciones asociadas a cada uno de los modelos de clasificación.




Figura 5.1: Ejemplo de arquitectura de control basada en una máquina de estados finitos para sistemas BCI. Tomado de [57]

Este procedimiento es consistente con diversas propuestas presentes en la literatura, donde el control de sistemas BCI se aborda mediante máquinas de estados finitos donde varios clasificadores de EEG son utilizados para detectar las distintas intenciones del usuario, tales como iniciar, mantener, o finalizar la marcha. En esta línea, Ferrero et al. [57] emplean una arquitectura de control basada en estados para gobernar la marcha de un exoesqueleto, mientras que los mismos autores [54] aplican un enfoque similar al control de una cinta de marcha.

Asimismo, Choi et al. [58] demostraron la viabilidad de este paradigma en sistemas de control asíncronos para exoesqueletos de miembro inferior, utilizando tres estados funcionales (parada, marcha y sentado) y transiciones activadas mediante imaginación motora.

BIBLIOGRAFÍA

- [1] World Health Organization (WHO). «Lesión de la médula espinal,» Organización Mundial de la Salud. (16 de abr. de 2024), dirección: <https://www.who.int/es/news-room/fact-sheets/detail/spinal-cord-injury> (visitado 29-04-2026).
- [2] S. A. Bravo, J. A. Porras y M. J. Á. Urricelqu, «La exclusión social, una problemática estructural entre las personas con discapacidad,» *Áreas. Revista Internacional de Ciencias Sociales*, n.º 36, págs. 167-181, 1 de nov. de 2017, ISSN: 1989-6190. dirección: <https://revistas.um.es/areas/article/view/308211> (visitado 29-04-2026).
- [3] G. Morone y R. S. Calabrò, «Neurorehabilitation Insights in 2024: Where Neuroscience Meets Next-Gen Tech,» *Brain Sciences*, vol. 15, n.º 10, pág. 1043, 25 de sep. de 2025, ISSN: 2076-3425. DOI: 10.3390/brainsci15101043. PMID: 41154139. dirección: <https://pmc.ncbi.nlm.nih.gov/articles/PMC12562376/> (visitado 04-05-2026).
- [4] M. T. Sadiq, M. Z. Aziz, A. Almogren, A. Yousaf, S. Siuly y A. U. Rehman, «Exploiting Pretrained CNN Models for the Development of an EEG-based Robust BCI Framework,» *Computers in Biology and Medicine*, vol. 143, pág. 105242, 1 de abr. de 2022, ISSN: 0010-4825. DOI: 10.1016/j.combiomed.2022.105242. dirección: <https://www.sciencedirect.com/science/article/pii/S0010482522000348> (visitado 27-04-2026).
- [5] S. Yun, «Advances, Challenges, and Prospects of Electroencephalography-Based Biomarkers for Psychiatric Disorders: A Narrative Review,» *Journal of Yeungnam Medical Science*, vol. 41, n.º 4, págs. 261-268, 9 de sep. de 2024, ISSN: 2799-8010. DOI: 10.12701/jyms.2024.00668. PMID: 39246060. dirección: <https://pmc.ncbi.nlm.nih.gov/articles/PMC11534409/> (visitado 06-05-2026).

- [6] M. C. Emos y S. Agarwal, «Neuroanatomy, Upper Motor Neuron Lesion,» en *StatPearls*, Treasure Island (FL): StatPearls Publishing, 2026. PMID: 30725990. dirección: <http://www.ncbi.nlm.nih.gov/books/NBK537305/> (visitado 12-05-2026).

- [7] K. Margetis, J. M. Das y P. D. Emmady, «Spinal Cord Injuries,» en *StatPearls*, Treasure Island (FL): StatPearls Publishing, 2026. PMID: 32809556. dirección: <http://www.ncbi.nlm.nih.gov/books/NBK560721/> (visitado 12-05-2026).

- [8] National Institute of Neurological Disorders and Stroke. «Spinal Cord Injury — National Institute of Neurological Disorders and Stroke.» (), dirección: <https://www.ninds.nih.gov/health-information/disorders/spinal-cord-injury> (visitado 12-05-2026).

- [9] I. Corral López, M. Morales Castillo y M. O. González Oria. «Traumatismo medular,» Manuales Clínicos. (2 de nov. de 2023), dirección: <https://manualclinico.hospitaluvrocio.es/urgencias-de-traumatologia/patologia-de-cabeza-y-tronco/traumatismo-medular/> (visitado 12-05-2026).

- [10] S. J. Murphy y D. J. Werring, «Stroke: Causes and Clinical Features,» *Medicine (Abingdon, England : UK Ed.)*, vol. 48, n.º 9, págs. 561-566, sep. de 2020, ISSN: 1357-3039. DOI: 10.1016/j.mpmed.2020.06.002. PMID: 32837228. dirección: <https://pmc.ncbi.nlm.nih.gov/articles/PMC7409792/> (visitado 12-05-2026).

- [11] Z. Gao, Z. Pang, Y. Chen, G. Lei, S. Zhu, G. Li, Y. Shen y W. Xu, «Restoring After Central Nervous System Injuries: Neural Mechanisms and Translational Applications of Motor Recovery,» *Neuroscience Bulletin*, vol. 38, n.º 12, págs. 1569-1587, 1 de dic. de 2022, ISSN: 1995-8218. DOI: 10.1007/s12264-

022-00959-x. dirección: <https://doi.org/10.1007/s12264-022-00959-x> (visitado 12-05-2026).

- [12] M. Puderbaugh y P. D. Emmady, «Neuroplasticity,» en *StatPearls*, Treasure Island (FL): StatPearls Publishing, 2026. PMID: 32491743. dirección: <http://www.ncbi.nlm.nih.gov/books/NBK557811/> (visitado 13-05-2026).
- [13] R. Di Palma, L. Falco, A. Coccia, F. Amitrano, G. Pagano y G. D'Addio, «Frontiers in neuro-rehabilitation: Neural basis of cognitive contributions to movement across neurological populations,» *Frontiers in Neurology*, vol. 16, 4 de jul. de 2025, ISSN: 1664-2295. DOI: 10.3389/fneur.2025.1638254. dirección: <https://www.frontiersin.org/journals/neurology/articles/10.3389/fneur.2025.1638254/full> (visitado 13-05-2026).
- [14] S. J. Luck, *An Introduction to the Event-Related Potential Technique*, 2.^a ed. Cambridge, MA, USA: MIT Press, 30 de mayo de 2014, 416 págs., ISBN: 978-0-262-52585-5.
- [15] D. L. Sherman y N. V. Thakor, «EEG Signal Processing: Theory and Applications,» en *Neural Engineering*, B. He, ed., Cham: Springer International Publishing, 2020, págs. 97-129, ISBN: 978-3-030-43395-6. DOI: 10.1007/978-3-030-43395-6_3. dirección: https://doi.org/10.1007/978-3-030-43395-6_3 (visitado 06-05-2026).
- [16] B. Jiang, X. Wang, D. He, S. Cheng, M. Liao, D. Miao, Q. Xia, Y. Zhao y G. Li, «A Comprehensive Review of Deep Learning for Motor Imagery EEG: From Healthy Subjects to Patients,» *Biomedical Signal Processing and Control*, vol. 117, pág. 109680, 15 de mayo de 2026, ISSN: 1746-8094. DOI: 10.1016/j.bspc.2026.109680. dirección: <https://www.sciencedirect.com/science/article/pii/S174680942600234X> (visitado 05-05-2026).

- [17] M. Roohi-Azizi, L. Azimi, S. Heysieattalab y M. Aamidfar, «Changes of the Brain's Bioelectrical Activity in Cognition, Consciousness, and Some Mental Disorders,» *Medical Journal of the Islamic Republic of Iran*, vol. 31, pág. 53, 3 de sep. de 2017, ISSN: 1016-1430. DOI: 10.14196/mjiri.31.53. PMID: 29445682. dirección: <https://pmc.ncbi.nlm.nih.gov/articles/PMC5804435/> (visitado 06-05-2026).
- [18] A. Craik, Y. He y J. L. Contreras-Vidal, «Deep learning for electroencephalogram (EEG) classification tasks: A review,» *Journal of Neural Engineering*, vol. 16, n.º 3, pág. 031 001, abr. de 2019, ISSN: 1741-2552. DOI: 10.1088/1741-2552/ab0ab5. dirección: <https://doi.org/10.1088/1741-2552/ab0ab5> (visitado 27-04-2026).
- [19] A. Telpaz, R. Webb y D. Levy, «Using EEG to Predict Consumers' Future Choices,» *Journal of Marketing Research*, 1 de ago. de 2015. DOI: 10.1509/jmr.13.0564.
- [20] R. T. Schirrmeister, J. T. Springenberg, L. D. J. Fiederer, M. Glasstetter, K. Eggensperger, M. Tangermann, F. Hutter, W. Burgard y T. Ball, «Deep learning with convolutional neural networks for EEG decoding and visualization,» *Human Brain Mapping*, vol. 38, n.º 11, págs. 5391-5420, 2017, ISSN: 1097-0193. DOI: 10.1002/hbm.23730. dirección: <https://onlinelibrary.wiley.com/doi/abs/10.1002/hbm.23730> (visitado 09-03-2026).
- [21] L. S. Vidyaratne y K. M. Iftexharuddin, «Real-Time Epileptic Seizure Detection Using EEG,» *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, vol. 25, n.º 11, págs. 2146-2156, nov. de 2017, ISSN: 1558-0210. DOI: 10.1109/TNSRE.2017.2697920. dirección: <https://ieeexplore.ieee.org/document/7911296> (visitado 06-05-2026).
- [22] S. Saha y M. Baumert, «Intra- and Inter-subject Variability in EEG-Based Sensorimotor Brain Computer Interface: A Review,» *Frontiers in Computatio-*

- nal Neuroscience*, vol. 13, pág. 87, 21 de ene. de 2020, ISSN: 1662-5188. DOI: 10.3389/fncom.2019.00087. PMID: 32038208. dirección: <https://pmc.ncbi.nlm.nih.gov/articles/PMC6985367/> (visitado 06-05-2026).
- [23] C. Tan, F. Sun y W. Zhang. «Deep Transfer Learning for EEG-based Brain Computer Interface.» arXiv: 1808.01752 [cs.CV]. (6 de ago. de 2018), dirección: <http://arxiv.org/abs/1808.01752> (visitado 06-06-2026), prepublicado.
- [24] R. J. Sugden, V.-L. L. Pham-Kim-Nghiem-Phu, I. Campbell, A. Leon y P. Diamandis, «Remote Collection of Electrophysiological Data with Brain Wearables: Opportunities and Challenges,» *Bioelectronic Medicine*, vol. 9, pág. 12, 21 de jun. de 2023, ISSN: 2332-8886. DOI: 10.1186/s42234-023-00114-5. PMID: 37340487. dirección: <https://pmc.ncbi.nlm.nih.gov/articles/PMC10283168/> (visitado 06-06-2026).
- [25] C. Rommel, J. Paillard, T. Moreau y A. Gramfort, «Data augmentation for learning predictive models on EEG: A systematic comparison,» *Journal of Neural Engineering*, vol. 19, n.º 6, pág. 066 020, nov. de 2022, ISSN: 1741-2552. DOI: 10.1088/1741-2552/aca220. dirección: <https://doi.org/10.1088/1741-2552/aca220> (visitado 06-06-2026).
- [26] M. J. Young, D. J. Lin y L. R. Hochberg, «Brain-Computer Interfaces in Neurorecovery and Neurorehabilitation,» *Seminars in neurology*, vol. 41, n.º 2, págs. 206-216, abr. de 2021, ISSN: 0271-8235. DOI: 10.1055/s-0041-1725137. PMID: 33742433. dirección: <https://pmc.ncbi.nlm.nih.gov/articles/PMC8768507/> (visitado 10-05-2026).
- [27] B. He, H. Yuan, J. Meng y S. Gao, «Brain-Computer Interfaces,» en *Neural Engineering*, B. He, ed., Cham: Springer International Publishing, 2020, págs. 131-183, ISBN: 978-3-030-43395-6. DOI: 10.1007/978-3-030-43395-

- 6_4. dirección: https://doi.org/10.1007/978-3-030-43395-6_4 (visitado 06-05-2026).
- [28] S. Waldert, «Invasive vs. Non-Invasive Neuronal Signals for Brain-Machine Interfaces: Will One Prevail?» *Frontiers in Neuroscience*, vol. 10, 27 de jun. de 2016, ISSN: 1662-453X. DOI: 10.3389/fnins.2016.00295. dirección: <https://www.frontiersin.org/journals/neuroscience/articles/10.3389/fnins.2016.00295/full> (visitado 01-06-2026).
- [29] J. R. Wolpaw y E. W. Wolpaw, *Brain-Computer Interfaces: Principles and Practice*. New York: Oxford University Press, 2012, ISBN: 978-0-19-993268-9.
- [30] M. F. Mridha, S. C. Das, M. M. Kabir, A. A. Lima, M. R. Islam e Y. Watanobe, «Brain-Computer Interface: Advancement and Challenges,» *Sensors (Basel, Switzerland)*, vol. 21, n.º 17, pág. 5746, 26 de ago. de 2021, ISSN: 1424-8220. DOI: 10.3390/s21175746. PMID: 34502636. dirección: <https://pmc.ncbi.nlm.nih.gov/articles/PMC8433803/> (visitado 29-04-2026).
- [31] D. J. McFarland, J. Daly, C. Boulay y M. Parvaz, «Therapeutic Applications of BCI Technologies,» *Brain computer interfaces (Abingdon, England)*, vol. 47, n.º 1–2, págs. 37-52, 2017, ISSN: 2326-263X. DOI: 10.1080/2326263X.2017.1307625. PMID: 29527538. dirección: <https://pmc.ncbi.nlm.nih.gov/articles/PMC5843196/> (visitado 02-06-2026).
- [32] Q. Deng, Z. Fu, N. Ma y B. Wang, «Application and Future Directions of Brain-Computer Interfaces in Neurological Disorders: Technological Advances, Clinical Practices, and Challenges,» *Brain Hemorrhages*, vol. 6, n.º 6, págs. 306-314, 1 de dic. de 2025, ISSN: 2589-238X. DOI: 10.1016/j.hest.2025.09.002. dirección: <https://www.sciencedirect.com/science/article/pii/S2589238X2500083X> (visitado 02-06-2026).

- [33] B. J. Edelman, S. Zhang, G. Schalk, P. Brunner, G. Müller-Putz, C. Guan y B. He, «Non-Invasive Brain-Computer Interfaces: State of the Art and Trends,» *IEEE Reviews in Biomedical Engineering*, vol. 18, págs. 26-49, 2025, ISSN: 1941-1189. DOI: 10.1109/RBME.2024.3449790. dirección: <https://ieeexplore.ieee.org/abstract/document/10646518/references> (visitado 25-05-2026).

- [34] S. Albawi, T. Abed Mohammed y S. ALZAWI, «Understanding of a Convolutional Neural Network,» 21 de ago. de 2017. DOI: 10.1109/ICEngTechnol.2017.8308186.

- [35] Y. LeCun, Y. Bengio y G. Hinton, «Deep learning,» *Nature*, vol. 521, n.º 7553, págs. 436-444, mayo de 2015, ISSN: 1476-4687. DOI: 10.1038/nature14539. dirección: <https://www.nature.com/articles/nature14539> (visitado 02-06-2026).

- [36] J. Schmidhuber, «Deep Learning in Neural Networks: An Overview,» *Neural Networks*, vol. 61, págs. 85-117, 1 de ene. de 2015, ISSN: 0893-6080. DOI: 10.1016/j.neunet.2014.09.003. dirección: <https://www.sciencedirect.com/science/article/pii/S0893608014002135> (visitado 02-06-2026).

- [37] I. Goodfellow, Y. Bengio y A. Courville, *Deep Learning*. MIT Press, 2016.

- [38] I. Rakhmatulin, M.-S. Dao, A. Nassibi y D. Mandic, «Exploring Convolutional Neural Network Architectures for EEG Feature Extraction,» *Sensors (Basel, Switzerland)*, vol. 24, n.º 3, pág. 877, 29 de ene. de 2024, ISSN: 1424-8220. DOI: 10.3390/s24030877. PMID: 38339594. dirección: <https://pmc.ncbi.nlm.nih.gov/articles/PMC10856895/> (visitado 02-06-2026).

- [39] C. M. Köllöd, A. Adolf, G. Márton e I. Ulbert, «Deep Comparisons of Neural Networks from the EEGNet Family,» *Electronics*, vol. 12, n.º 12, pág. 2743, 20 de jun. de 2023, ISSN: 2079-9292. DOI: 10.3390/electronics12122743.

- arXiv: 2302.08797 [eess.SP]. dirección: <http://arxiv.org/abs/2302.08797> (visitado 19-05-2026).
- [40] V. J. Lawhern, A. J. Solon, N. R. Waytowich, S. M. Gordon, C. P. Hung y B. J. Lance, «EEGNet: A Compact Convolutional Network for EEG-based Brain-Computer Interfaces,» *Journal of Neural Engineering*, vol. 15, n.º 5, pág. 056013, 1 de oct. de 2018, ISSN: 1741-2560, 1741-2552. DOI: 10.1088/1741-2552/aace8c. arXiv: 1611.08024 [cs]. dirección: <http://arxiv.org/abs/1611.08024> (visitado 25-04-2025).
- [41] Y. Roy, H. Banville, I. M. Carneiro de Albuquerque, A. Gramfort, T. Falk y J. Faubert, «Deep Learning-Based Electroencephalography Analysis: A Systematic Review,» *Journal of Neural Engineering*, vol. 16, 14 de ago. de 2019. DOI: 10.1088/1741-2552/ab260c.
- [42] Z. Wan, R. Yang, M. Huang, N. Zeng y X. Liu, «A Review on Transfer Learning in EEG Signal Analysis,» *Neurocomputing*, vol. 421, págs. 1-14, 15 de ene. de 2021. DOI: 10.1016/j.neucom.2020.09.017.
- [43] J. Ma, B. Yang, W. Qiu, Y. Li, S. Gao y X. Xia, «A large EEG dataset for studying cross-session variability in motor imagery brain-computer interface,» *Scientific Data*, vol. 9, n.º 1, pág. 531, 1 de sep. de 2022, ISSN: 2052-4463. DOI: 10.1038/s41597-022-01647-1. dirección: <https://www.nature.com/articles/s41597-022-01647-1> (visitado 06-06-2026).
- [44] D.-J. Sung, K.-T. Kim, J.-H. Jeong, L. Kim, S. J. Lee, H. Kim y S.-J. Kim, «Improving Inter-Session Performance via Relevant Session-Transfer for Multi-Session Motor Imagery Classification,» *Heliyon*, vol. 10, n.º 17, e37343, 15 de sep. de 2024, ISSN: 2405-8440. DOI: 10.1016/j.heliyon.2024.e37343. dirección: <https://www.sciencedirect.com/science/article/pii/S2405844024133749> (visitado 03-06-2026).

- [45] D. Wu, Y. Xu y B.-L. Lu. «Transfer Learning for EEG-Based Brain-Computer Interfaces: A Review of Progress Made Since 2016,» arXiv.org. (13 de abr. de 2020), dirección: <https://arxiv.org/abs/2004.06286v4> (visitado 03-06-2026).

- [46] Z. Otarbay y A. Kyzzyrkanov, «Transfer learning for subject-independent motor imagery EEG classification using convolutional relational networks,» *Frontiers in Neuroscience*, vol. 19, 2 de ene. de 2026, ISSN: 1662-453X. DOI: 10.3389/fnins.2025.1691929. dirección: <https://www.frontiersin.org/journals/neuroscience/articles/10.3389/fnins.2025.1691929/full> (visitado 03-06-2026).

- [47] S. An, M. Kang, S. Kim, P. Chikontwe, L. Shen y S. H. Park, «Subject-Adaptive Transfer Learning Using Resting State EEG Signals for Cross-Subject EEG Motor Imagery Classification,» en *Medical Image Computing and Computer Assisted Intervention – MICCAI 2024*, M. G. Linguraru, Q. Dou, A. Feragen, S. Giannarou, B. Glocker, K. Lekadir y J. A. Schnabel, eds., vol. 15011, Cham: Springer Nature Switzerland, 2024, págs. 678-688, ISBN: 978-3-031-72119-9 978-3-031-72120-5. DOI: 10.1007/978-3-031-72120-5_63. dirección: https://link.springer.com/10.1007/978-3-031-72120-5_63 (visitado 03-06-2026).

- [48] W. Lu, H. Liu, H. Ma, T.-P. Tan y L. Xia, «Hybrid Transfer Learning Strategy for Cross-Subject EEG Emotion Recognition,» *Frontiers in Human Neuroscience*, vol. 17, pág. 1280241, 16 de nov. de 2023, ISSN: 1662-5161. DOI: 10.3389/fnhum.2023.1280241. PMID: 38034069. dirección: <https://pmc.ncbi.nlm.nih.gov/articles/PMC10687359/> (visitado 03-06-2026).

- [49] M. Wimpff, B. Aristimunha, S. Chevallier y B. Yang. «Fine-Tuning Strategies for Continual Online EEG Motor Imagery Decoding: Insights from a Large-Scale Longitudinal Study.» ver. 1. (2025), dirección: <https://arxiv.org/abs/2502.06828> (visitado 03-06-2026), prepublicado.

- [50] C.-J. Huang, C.-F. Cao, K. K. Shyu, T.-M. Lee y P.-L. Lee, «Continual-Learning-Enhanced CNN-Transformer Framework for Real-Time Motor-Imagery BCI in Virtual Environments,» *Bioengineering*, vol. 13, n.º 5, pág. 536, mayo de 2026, ISSN: 2306-5354. DOI: 10.3390/bioengineering13050536. dirección: <https://www.mdpi.com/2306-5354/13/5/536> (visitado 03-06-2026).
- [51] A. Abu-Rmileh, E. Zakkay, L. Shmuelof y O. Shriki, «Co-adaptive Training Improves Efficacy of a Multi-Day EEG-Based Motor Imagery BCI Training,» *Frontiers in Human Neuroscience*, vol. 13, 14 de oct. de 2019, ISSN: 1662-5161. DOI: 10.3389/fnhum.2019.00362. dirección: <https://www.frontiersin.org/journals/human-neuroscience/articles/10.3389/fnhum.2019.00362/full> (visitado 03-06-2026).
- [52] «Introduction to Altair in Python,» GeeksforGeeks. (19 de jul. de 2025), dirección: <https://www.geeksforgeeks.org/python/introduction-to-altair-in-python/> (visitado 07-04-2026).
- [53] «Why DuckDB,» DuckDB. (2026), dirección: https://duckdb.org/why_duckdb.html (visitado 07-04-2026).
- [54] L. Ferrero, V. Quiles, M. Ortiz, E. Ianez y J. M. Azorin, «BCI Based on Lower-Limb Motor Imagery and a State Machine for Walking on a Treadmill,» en *2021 10th International IEEE/EMBS Conference on Neural Engineering (NER)*, Italy: IEEE, 4 de mayo de 2021, págs. 1-4, ISBN: 978-1-7281-4337-8. DOI: 10.1109/NER49283.2021.9441216. dirección: <https://ieeexplore.ieee.org/document/9441216/> (visitado 29-08-2025).
- [55] M. Mirnaziri, M. Rahimi, S. Alavikakhaki y R. Ebrahimpour, «Using Combination of μ , B and Y Bands in Classification of EEG Signals,» *Basic and Clinical Neuroscience*, vol. 4, n.º 1, págs. 76-87, 2013, ISSN: 2008-126X. PMID: 25337331. dirección: <https://pmc.ncbi.nlm.nih.gov/articles/PMC4202559/> (visitado 21-05-2026).

- [56] P. Venkataanusha, C. Anuradha, D. Murty y S. Chebrolu, «Detecting Outliers in High Dimensional Data Sets Using Z-Score Methodology,» *International Journal of Innovative Technology and Exploring Engineering*, vol. 9, págs. 48-53, 30 de nov. de 2019. DOI: 10.35940/ijitee.A3910.119119.

- [57] L. Ferrero, V. Quiles, M. Ortiz, E. Iáñez y J. M. Azorín, «A BMI Based on Motor Imagery and Attention for Commanding a Lower-Limb Robotic Exoskeleton: A Case Study,» *Applied Sciences*, vol. 11, n.º 9, pág. 4106, ene. de 2021, ISSN: 2076-3417. DOI: 10.3390/app11094106. dirección: <https://www.mdpi.com/2076-3417/11/9/4106> (visitado 29-08-2025).

- [58] J. Choi, K. Kim, J. Jihyeok, L. Kim, S. Lee y H. Kim, «Developing a Motor Imagery-Based Real-Time Asynchronous Hybrid BCI Controller for a Lower-Limb Exoskeleton,» *Sensors*, vol. 20, pág. 7309, 19 de dic. de 2020. DOI: 10.3390/s20247309.

ANEXOS

tantos como se considere necesario en funci3n de los aspectos concretos que se quieran especificar.

A. Primer anexo

Contenido del primer anexo (texto, tablas, figuras, c3digos, etc.)

B. Segundo anexo

Contenido del segundo anexo (texto, tablas, figuras, códigos, etc.)

interwordspace: 3.91663pt

interwordstretch: 1.95831pt

emergencystretch: 35.24963pt